Verjetnost in statistika - definicije, trditve in izreki

Oskar Vavtar
po predavanjih profesorja Jaka Smrekarja

2020/21

Kazalo

1 SLUČAJNI VEKTORJI

Definicija 1.1 (Komulativna porazdelitvena funkcija)**.** Slučajni vektor je taka funkcija/preslikava $\vec{X} = (X_1, \ldots, X_n) : \Omega \to \mathbb{R}^n$, kjer je Ω verjetnostni prostor, za katero so množice

$$\begin{aligned}
\{X_1 \leq x_1, \ldots, X_n \leq x_n\} &= \{X_1 \in (-\infty, x_1], \ldots, X_n \in (-\infty, x_n]\} \\
&= \{\vec{X} \in (-\infty, x_1] \times \ldots \times (-\infty, x_n]\} \\
&= \vec{X}^{-1}\left((-\infty, x_1] \times \ldots \times (-\infty, x_n]\right)
\end{aligned}$$

dogodki za vse *realne* n-terice $(x_1, \ldots, x_n) \in \mathbb{R}^n$.

Komulativna porazdelitvena funkcija slučajnega vektorja $\vec{X}$ je funkcija $F_X : \mathbb{R}^n \to [0, 1]$ s predpisom

$$F_{\vec{X}}(x_1, \ldots, x_n) = \mathbb{P}(X_1 \leq x_1, \ldots, X_n \leq x_n).$$

Trditev 1.1 (Lastnosti KPF)**.**

(1)

$$\begin{aligned}
\lim_{x_i \to -\infty} F_{\vec{X}}(x_1, \ldots, x_n) &= 0 \\
\lim_{\substack{x_1 \to \infty \\ \cdots \\ x_n \to \infty}} F_{\vec{X}}(x_1, \ldots, x_n) &= 1
\end{aligned}$$

(2) MONOTONOST:
Če je $x_i \leq y_i$ za $\forall i \in \{1, \ldots, n\}$, je

$$F_{\vec{X}}(x_1, \ldots, x_n) = F_{\vec{X}}(\vec{x}) \leq F_{\vec{X}}(\vec{y}).$$

To sledi iz monotonosti $\mathbb{P}$.

(3) ZVEZNOST Z DESNE:

$$\lim_{\vec{y} \searrow \vec{x}} F_{\vec{X}}(\vec{y}) = F_{\vec{X}}(\vec{x})$$

Tu $\vec{y} \searrow \vec{x}$ interpretiramo kot $\vec{y_i} \searrow \vec{x_i}$ za $\forall i$.

Opomba. Lastnosti (1), (2) in (3) karakterizirajo družino abstraktnih komulativnih porazdelitvenih funkcij v primeru slučajnih spremeljivk ($n = 1$). V večrazsežnem prostoru to ne drži.

Izrek 1.1. Če je $F : \mathbb{R}^2 \to [0, 1]$ zadošča (1), (2), (3) in (4):

$$F(b, d) - F(a, d) - F(b, c) + F(a, c) \ \geq \ 0$$

za vse četverice $a < b$ in $c < d$, je F *komulativna porazdelitvena funkcija* nekega slučajnega vektorja $(X, Y) : \Omega \to \mathbb{R}^2$.

Definicija 1.2 ("Zvezni" slučajni vektorj)**.** Slučajni vektor $\vec{X} : \Omega \to \mathbb{R}^n$ ima (*zvezno*) gostoto, če obstaja taka *zvezna* funkcija $f_{\vec{X}} : \mathbb{R}^n \to [0, \infty)$, da zanjo velja

$$\mathbb{P}(\vec{x} \in \mathcal{B}) \ = \ \int_{\mathcal{B}} f_{\vec{X}}(x_1, \ldots, x_n)\, dx_1 \ldots dx_n,$$

za vsako Borelovo množico $\mathcal{B} \subset \mathbb{R}^n$.

Posplošitev. Pravimo, da ima vektor $\vec{X} = (X_1, \ldots, X_n)$ n-razsežno normalno porazdelitev s parametrom $\vec{\mu} \in \mathbb{R}$ in $\Sigma \in \mathbb{R}^{n \times n}$ (*simetrična* in *pozitivno definitna*), če ima gostoto:

$$f_{\vec{X}}(\vec{x}) \ = \ (2\pi)^{-\frac{n}{2}} (\det \Sigma)^{-1} e^{-\frac{1}{2}\langle \ \Sigma^{-1}(\vec{x}-\vec{\mu}) \ , \ (\vec{x}-\vec{\mu}) \ \rangle}$$

2 NEODVISNOST

Definicija 2.1. Komponente $X_1, \ldots, X_n$ slučajnega vektorja $\vec{X} = (X_1, \ldots, X_n)$ so *neodvisne*, če velja

$$F_{\vec{X}}(x_1, \ldots, x_n) \;=\; F_{X_1}(x_1) \cdot \ldots \cdot F_{X_n}(x_n)$$

za vse n-terice $(x_1, \ldots, x_n) \in \mathbb{R}^n$.

Opomba. Enakost lahko prepišemo v

$$\mathbb{P}\left(\vec{X} \in (-\infty, x_1] \times \ldots \times (-\infty, x_n]\right) \;=\; \mathbb{P}\left(X_1 \in (-\infty, x_1]\right) \cdot \ldots \cdot \mathbb{P}\left(X_n \in (-\infty, x_n]\right)$$

Trditev 2.1. Naj ima (X, Y) *"zvezno"* gostoto $f(X, Y)$ in naj bosta f_X in f_Y robni gostoti. Tedaj sta X in Y *neodvisni* natanko takrat, ko

$$f_{(X,Y)}(x, y) \;=\; f_X(x) \cdot f_Y(y)$$

za skoraj vse pare x in y.

Trditev 2.2 (Posledica prejšnje trditve)**.** Naj ima (X, Y) *"zvezno"* gostoto $f_{(X,Y)}(x, y)$. Tedaj sta X in Y neodvisni natanko takrat, ko velja

$$f_{(X,Y)}(x, y) \;=\; \Phi(x)\Psi(y)$$

za skoraj vse x in y, za neki *nenegativni* integralski funkciji.

3 FUNKCIJE in TRANSFORMACIJE slučajnih spremenljivk in vektorjev

3.1 Slučajne spremenljivke

Trditev 3.1 (Diskretni primer)**.** Če je X *diskretna slučajna spremenljivka* z vrednostmi $\{x_i \mid i \in I\}$ in je g funkcija, ki preslika množico $\{x_i \mid i \in I\}$ na množico $\{y_j \mid j \in J\}$, je $g \circ X = g(X)$ *diskretna slučajna spremenljivka* z verjetnostno funkcijo

$$\mathbb{P}(g(X) = y_j) \;=\; \sum_{i:\; g(x_i)=y_j} \mathbb{P}(X = x_i)$$

Trditev 3.2 (Zvezni primer)**.** Naj ima slučajna spremenljivka X *"zvezno"* gostoto f_X, ki je različna od 0 natanko na intervalu (a,b), kjer $-\infty \le a \le b \le \infty$.

Naj bo $g : (a,b) \to (c,d)$ *zvezna bijekcija.* Zanima nas funkcija $g(X)$ slučajne spremenljivke X.

Velja tudi

$$\mathbb{P}(X \in (a,b)) \;=\; \int_a^b f_X(x)\,dx \;=\; \int_{\mathbb{R}} f_X(x)\,dx \;=\; 1.$$

Velja $\{g(X) \le z\} = \{X \le g^{-1}(z)\}$. Ker je X slučajna spremenljivka, so $\{X \le g^{-1}(z)\}$ dogodki za $z \in (c,d)$. Sledi, da je $g(X)$ slučajna spremenljivka in velja:

$$F_{g(X)}(z) \;=\; \mathbb{P}(g(X) \le z) \;=\; \begin{cases} 1 & ; \quad z \ge d \\ F_X(g^{-1}(z)) \; ; & \quad z \in (c,d) \\ 0 & ; \quad z \le c \end{cases}$$

Če je g *odvedljiva*, sledi:

$$f_{g(X)}(z) \;=\; \frac{d}{dz} F_{g(X)}(z) \;=\; \begin{cases} \frac{f_X(g^{-1}(z))}{g'(g^{-1}(z))} \; ; & \quad z \in (c,d) \\ 0 & ; \; \text{sicer} \end{cases}$$

Za splošno *odvedljivo bijekcijo* $g : (a,b) \to (c,d)$ velja t.i. *transformacijska formula*:

$$f_{g(X)}(z) \;=\; \frac{f_X(g^{-1}(z))}{|g'(g^{-1}(z))|}, \quad \text{za } z \in (c,d).$$

3.2 Slučajni vektorji

Trditev 3.3. Naj bo $\vec{X} : \Omega \to \mathbb{R}^n$ slučajni vektor in naj bo $h : \mathbb{R}^n \to \mathbb{R}$ *zvezna* funkcija. Tedaj je $h(\vec{X}) = h(X_1, \ldots, X_n)$ *slučajna spremenljivka.*

Trditev 3.4. Naj bo $\vec{X} : \Omega \to \mathbb{R}^n$ slučajni vektor z gostoto $f_{\vec{X}}$. Dalje naj bo $g : \mathbb{R}^n \to \mathbb{R}^n$ (ali $g : D \to E$ za primerni množici $D, E \subset \mathbb{R}^n$, kjer $\mathbb{P}(\vec{X} \in D) = 1$) *zvezno diferenciabilna bijekcija.* Tedaj ima slučajni vektor $g(\vec{X})$ gostoto

$$f_{g(\vec{X})}(\vec{z}) \;=\; f_{\vec{X}}(g^{-1}(\vec{z})) \cdot |\det Jg^{-1}(\vec{z})|$$

v točkah $\vec{z} \in \mathbb{R}^n$ (oz. $\vec{z} \in E$).

Za dvorazsežne vektorje, kjer je $\vec{z} = (u, v)$ in $(U, V) = g(X, Y)$ ter posledično $(X, Y) = g^{-1}(U, V)$ se transformacijska formula glasi

$$f_{(U,V)}(u, v) \;=\; f_{(X,Y)}(g^{-1}(u, v)) \cdot |\det Jg^{-1}(u, v)|$$

oziroma

$$f_{(U,V)}(u, v) \;=\; f_{(X,Y)}(x(u, v), y(u, v)) \cdot \left| \begin{vmatrix} \frac{\partial x}{\partial u} & \frac{\partial x}{\partial v} \\ \frac{\partial y}{\partial u} & \frac{\partial y}{\partial v} \end{vmatrix} \right|.$$

Upoštevaje $g \circ g^{-1} = \mathrm{id}$ in posledično

$$Jg(g^{-1}(u, v)) \cdot Jg^{-1}(u, v) \;=\; I$$

zgornje prepišemo v

$$f_{(U,V)}(u, v) \;=\; \frac{f_{(X,Y))}(g^{-1}(u, v))}{|\det Jg(g^{-1}(u, v))|} \;=\; \frac{f_{(X,Y)}(x(u, v), y(u, v))}{\left| \begin{vmatrix} \frac{\partial u}{\partial x} & \frac{\partial u}{\partial y} \\ \frac{\partial v}{\partial x} & \frac{\partial v}{\partial y} \end{vmatrix} \Big|_{(x(u,v),\ y(u,v))} \right|}.$$

Trditev 3.5. Naj za $\vec{X} : \Omega \to \mathbb{R}^n$ velja $\vec{X} \sim N(\vec{\mu}, \Sigma)$ in naj bo $A : \mathbb{R}^n \to \mathbb{R}^n$ *obrnljiva* matrika. Dalje naj bo $\vec{\nu} \in \mathbb{R}^n$. Tedaj

$$A\vec{X} + \vec{\nu} \sim \mathcal{N}(A\vec{\mu} + \vec{\nu}, A\Sigma A^T).$$

4 PRIČAKOVANA VREDNOST zveznih slučajnih spremenljivk in vektorjev

Definicija 4.1. Naj bo X slučajna spremenljivka z "zvezno" gostoto $f_X : \mathbb{R} \to [0, \infty)$. *Pričakovana vrednost* slučajne spremenljivke X je

$$\mathbb{E}(X) \;=\; \int_{-\infty}^{\infty} x \cdot f_X \, dx,$$

če integral absolutno konvergira.

Za slučajni vektor $\vec{X} = (X_1, \ldots, X_n)$ definiramo pričakovano vrednost po komponentah

$$\mathbb{E}(\vec{X}) \;=\; (\mathbb{E}(X_1), \ldots, \mathbb{E}(X_2)) \in \mathbb{R}^n.$$

Podobno definiramo tudi pričakovano vrednost slučajnih matrik.

4.1 Pričakovana vrednost funkcij slučajnih spremenljivk in vektorjev

Trditev 4.1. Naj bo $g : \mathbb{R} \to \mathbb{R}$ (ali $g : (a, b) \to (c, d)$) zvezna funkcija. Tedaj je

$$\mathbb{E}(g(X)) \;=\; \int_{-\infty}^{\infty} g(x) f_X(x) \, dx,$$

če obstaja.

Posledica. Za $p \neq 0$ velja:

$$\mathbb{E}(|x|^p) \;=\; \int_0^{\infty} |z|^p (f_X(z) + f_X(-z)) \, dz \;=\; \ldots \;=\; \int_{-\infty}^{\infty} |x|^p f_X(x) \, dx.$$

Trditev 4.2. Naj bo $h : \mathbb{R}^2 \to \mathbb{R}$ (oziroma $h : D \to \mathbb{R}$ v primeru, da $\mathbb{P}((X,Y) \in D) = 1$) *zvezna* funkcija in (X,Y) slučajni vektor z gostoto $f_{(X,Y)}$. Tedaj velja

$$\mathbb{E}(h(X,Y)) \;=\; \int_{R^2 \ (ali\ D)} h(x,y) f_{(X,Y)}(x,y)\, dx\, dy,$$

če obstaja.

Posledica.

$$\mathbb{E}(XY) \;=\; \int_{\mathbb{R}} x \cdot y \cdot f_{(X,Y)}(x,y)\, dx\, dy,$$

če integral absolutno konvergira.

Opomba. Če sta X in Y *neodvisni* slučajni spremenljivki, za kateri obstajata $\mathbb{E}(X)$ in $\mathbb{E}(Y)$, potem obstaja $\mathbb{E}(XY)$ in je

$$\mathbb{E}(XY) \;=\; \mathbb{E}(X) \cdot \mathbb{E}(Y).$$

Posledica (Aditivnosti pričakovane vrednosti)**.** Če je $X \leq Y$ (z verjetnostjo 1), velja

$$\mathbb{E}(X) \;\leq\; \mathbb{E}(Y)$$

če $\mathbb{E}(|Y|) < \infty$).

Izrek 4.1. Naj za slučajni spremenljivki X in Y velja $\mathbb{E}(X^2) < \infty$ in $\mathbb{E}(Y^2) < \infty$. Tedaj obstaja $\mathbb{E}(XY)$ in velja

$$\mathbb{E}(|XY|) \;\leq\; \sqrt{\mathbb{E}(X^2)\mathbb{E}(Y^2)}.$$

$$\text{Enakost nastopi} \quad \Longleftrightarrow \quad \frac{Y}{\sqrt{\mathbb{E}(Y^2)}} = \pm \frac{X}{\sqrt{\mathbb{E}(X^2)}} \text{ skoraj gotovo.}$$

Posledica. Če je $\mathbb{E}(X^2) < \infty$, je $\mathbb{E}(|X|) < \infty$ in

$$\mathbb{E}(|X|) \;\leq\; \sqrt{\mathbb{E}(X^2)}.$$

4.2 Disperzija, kovarianca in variančno-kovariančno matrika

Definicija 4.2. *Disperzija (razpršenost, varianca)* slučajne spremenljivke X je

$$\mathbb{E}((X - \mathbb{E}(X))^2),$$

če ta pričakovana vrednost obstaja. Ta obstaja, če obstaja $\mathbb{E}(X^2)$ in tedaj velja

$$Var(X) \;=\; \mathbb{E}(X^2) - \mathbb{E}(X)^2.$$

Definicija 4.3. *Standardni odklon* slučajne spremenljivke X definiramo kot

$$\sigma(X) \;=\; \sigma_X \;=\; \sqrt{Var(X)}.$$

Pripomnimo, da ima $\sigma(X)$ iste enote kot X in je zato $\sigma(X)$ "količina" ki je neposredno primerljiva z X.

Trditev 4.3 (Lastnosti variance)**.** Naj za slučajno spremenljivko X obstaja $\mathbb{E}(X^2)$ (torej obstaja tudi $Var(X)$):

- $Var(X) \geq 0$ in $Var(X) = 0 \iff X \equiv \mathbb{E}(X)$ skoraj gotovo,
- $Var(X)$ je minimum funkcije $a \mapsto \mathbb{E}((X - a)^2)$,
- $Var(aX + b) = a^2 Var(X)$,
- $Var(X + Y) = Var(X) + Var(Y)$, če sta X in Y *neodvisni.*

Komentar. Vemo, da je σ^2 v $\mathcal{N}(\mu, \sigma^2)$ disperzija.

Opomba. Za *zvezno* slučajno spremenljivko X z gostoto f_X je

$$Var(X) \;=\; \int_{-\infty}^{\infty} (x - \mathbb{E}(X))^2 f_X(x)\, dx.$$

Definicija 4.4. *Kovarianca* slučajnih spremenljivk X in Y je

$$Cov(X,Y) \;=\; \mathbb{E}((X-\mathbb{E}(X))(Y-\mathbb{E}(Y))),$$

če obstaja. $Cov(X,Y)$ obstaja, če obstajajo $\mathbb{E}(X)$, $\mathbb{E}(Y)$, $\mathbb{E}(XY)$. Če je tako, velja

$$Cov(X,Y) \;=\; \mathbb{E}(XY)-\mathbb{E}(X)\mathbb{E}(Y).$$

Če sta X in Y neodvisni in imata pričakovano vrednost, potem

$$Cov(X,Y) \;=\; 0.$$

Trditev 4.4 (Lastnosti kovariance)**.**

- $Cov(X,Y)$ obstaja, če obstajata $Var(X)$ in $Var(Y)$ ter velja *Cauchy-Schwarzova neenakost*

  $$|Cov(X,Y)| \;\leq\; \sqrt{Var(X)Var(Y)} \;=\; \sigma(X)\sigma(Y),$$

  enakost nastopi $\iff$ $\frac{Y-\mathbb{E}(Y)}{\sigma(Y)} = \pm\frac{X-\mathbb{E}(X)}{\sigma(X)}$ skoraj gotovo. V tem primeru pravimo, da sta X in Y skoraj gotovo linearno povezani.

- $Cov(X,X) = Var(X)$

- Kovarianca je *simetrična bilinearna* funkcija. Dovolj je preveriti bilinearnost v eni spremenljivki.

- Če ima (X,Y) *zvezno* gostoto f_X, potem je

  $$Cov(X,Y) \;=\; \iint_{\mathbb{R}^2}(x-\mathbb{E}(X))(y-\mathbb{E}(Y))f_{(X,Y)}(x,y)\,dx\,dy.$$

- Če imata X in Y disperzijo, jo ima tudi $X+Y$ in velja

  $$Var(X+Y) \;=\; Var(X)+2Cov(X,Y)+Var(Y).$$

  Posplošitev na disperzijo vrste $X_1+\ldots+X_n$:

  $$Var(X_1+\ldots+X_n) \;=\; \sum_{i=1}^{n} Var(X_i) \;+\; 2\sum_{1\leq i<j\leq n} Cov(X_i,X_j)$$

Definicija 4.5. *Variančno-kovariančna matrika* slučajnega vektorja $\vec{X} = (X_1, \ldots, X_n)$ je matrika $Var(\vec{X}) \in \mathbb{R}^{n\times n}$ z elementi

$$[Var(\vec{X})]_{ij} \;=\; Cov(X_i, X_j).$$

To je *simetrična* matrika z diagonalnimi elementi $Var(X_1), \ldots, Var(X_n)$.

Definicija 4.6. *Pearsonov korelacijski koeficient* slučajnih spremenljivk X in Y z disperzijo je

$$\rho(X,Y) \;=\; \frac{Cov(X,Y)}{\sigma(X)\sigma(Y)} \in [-1,1].$$

Definicija 4.7. Slučajni spremenljivki X in Y sta *nekorelirani* natanko takrat, ko

$$\mathbb{E}(XY) \;=\; \mathbb{E}(X)\mathbb{E}(Y).$$

Vidimo:

- Če sta X in Y *neodvisni* slučajni spremenljivki s pričakovano vrednostjo, sta *nekorelirani.*
- Obrat v splošnem ne drži, drži pa v primeru dvorazsežne normalno porazdeljenega slučajnega vektorja.
- Če imata X in Y disperzijo, sta nekorelirani $\iff$ $\rho(X,Y) = 0$.

5 POGOJNE PORAZDELITVE in POGOJNA PRIČAKOVANA VREDNOST

Definicija 5.1. Naj bo $\mathcal{B} \subseteq \mathbb{R}$ Borelova množica. Pogojna verjetnost, da Y zavzame vrednost v $\mathcal{B}$ pri pogoju $X = x$ je

$$\begin{aligned}\mathbb{P}(Y \in \mathcal{B} \mid X = x) &= \lim_{h \searrow 0} \mathbb{P}(Y \in \mathcal{B} \mid X \in (x-h, x+h)) = \\ &= \lim_{h \searrow 0} \frac{\mathbb{P}(Y \in \mathcal{B},\ X \in (x-h, x+h))}{\mathbb{P}(X \in (x-h, x+h))},\end{aligned}$$

če ta limita obstaja.

Trditev 5.1. Naj ima (X, Y) *"zvezno"* gostoto $f_{(X,Y)}$ in naj bo $f_X(x)$ *zvezna* v x. Tedaj je

$$\mathbb{P}(Y \in \mathcal{B} \mid X = x) = \int_{\mathcal{B}} \frac{f_{(X,Y)}(x, y)}{f_X(x)}\, dy.$$

Opomba. Če sta X, Y *neodvisni*, je

$$f_{(Y|X)}(y \mid x) = f_Y(y).$$

Brez privzetka *zveznosti* je

$$\mathbb{P}(Y \in \mathcal{B} \mid X = x) = \mathbb{P}(Y = \mathcal{B}).$$

Trditev 5.2. Velja tako imenovani *zakon popolne verjetnosti*:

$$\mathbb{P}(Y \in \mathcal{B}) = \int_{-\infty}^{\infty} \mathbb{P}(Y \in \mathcal{B} \mid X = x) f_X(x)\, dx.$$

Definicija 5.2. *Pogojna pričakovana vrednost* Y, pogojna na $X = x$, je pričakovana vrednost pogojne porazdelitve $(Y \mid X = x)$. V primeru, ko ima (X, Y) *"zvezno"* gostoto, to pomeni

$$\mathbb{E}(Y \mid X = x) = \int_{-\infty}^{\infty} y \cdot f_{(Y|X)}(y \mid x)\, dy.$$

Trditev 5.3. Zakon *popolne pričakovane vrednosti*:

$$\mathbb{E}(Y) \;=\; \int_{-\infty}^{\infty} \mathbb{E}(Y \mid X = x) f_X(x)\, dx.$$

Komentar. Velja tudi:

$$\begin{aligned} \mathbb{E}(g(Y) \mid X = x) \;&=\; \int_{-\infty}^{\infty} g(y) f_{(Y|X)}(y \mid x)\, dy \\ \text{in} \qquad \mathbb{E}(g(Y)) \;&=\; \int_{-\infty}^{\infty} \mathbb{E}(g(y) \mid X = x) f_X(x)\, dx. \end{aligned}$$

Definicija 5.3. Pogojna pričakovana vrednost $\mathbb{E}(Y \mid X)$ je slučajna spremenljivka, definirana[1] kot:

$$\mathbb{E}(Y \mid X)(\omega) \;=\; \mathbb{E}(Y \mid X = X(\omega)).$$

Če pišemo $g(x) = \mathbb{E}(Y \mid X = x)$, je $\mathbb{E}(Y \mid X) = g(X)$ *transformacija* slučajne spremenljivke X.

Sledi:

$$\begin{aligned} \mathbb{E}(\mathbb{E}(Y \mid X)) \;=\; \mathbb{E}(g(X)) \;&=\; \int_{-\infty}^{\infty} g(y) f_X(x)\, dx \;= \\ &=\; \int_{-\infty}^{\infty} \mathbb{E}(Y \mid X = x) f_X(x)\, dx \;=\; \mathbb{E}(Y). \end{aligned}$$

Pravimo, da je $\mathbb{E}(Y \mid X)$ najboljši približek za Y, če poznamo X.

[1] Na istem verjetnostnem prostoru.

6 MOMENTI in MOMENTNO-RODOVNA FUNKCIJA

Definicija 6.1. Naj bo X slučajna spremenljivka in naj bosta $k \in \mathbb{N}$ in $a \in \mathbb{R}$. Moment slučajne spremenljivke X glede na a je

$$m_k(a) \;=\; \mathbb{E}((X-a)^k),$$

če obstaja, torej če $\mathbb{E}(|X-a|^k) < \infty$.

V zveznem primeru je

$$m_k(a) \;=\; \int_{-\infty}^{\infty} (x-a)^k f(x)\, dx,$$

če integral absolutno konvergira.

Pravimo:

- $m_k(0) \ldots k$-ti *začetni* moment
- $m_k(\mathbb{E}(k)) \ldots k$-ti *centralni* moment

Trditev 6.1. Če obstaja $m_n(a)$, potem obstajajo $m_k(a)$ za $k < n$.

Trditev 6.2. Če obstaja $m_n(a)$ za neki $a \in \mathbb{R}$, obstaja $m_n(b)$ za $b \in \mathbb{R}$.

Posledica. Če m_n obstaja, je

$$m_n(b) \;=\; \sum_{k=0}^{\infty} \binom{n}{k} (a-b)^{n-k} m_n(a).$$

Izrek 6.1. Naj obstajajo vsi momenti $m_k = \mathbb{E}(X^k)$ in naj vrsta

$$\sum_{k=0}^{\infty} \frac{1}{k!} t^k \mathbb{E}(X^k)$$

absolutno konvergira za neki $t > 0$. Potem je porazdelitev slučajne spremenljivke X enolično določena z momenti. Če ima Y enako lastnost in velja

$$\mathbb{E}(X^k) \;=\; \mathbb{E}(Y^k) \quad \forall k,$$

sta X in Y *enako porazdeljeni.*

Komentar. To pomeni, da je komulativna porazdelitvena funkcija $F_X : \mathbb{R} \to [0,1]$ določena s *števnim* naborom števil.

Definicija 6.2. *Momentno-rodovna funkcija* slučajne spremenljivke X je funkcija

$$M_X(t) \;=\; \mathbb{E}(e^{tX}),$$

ki je definirana za tista realna števila $t \in \mathbb{R}$, za katera pričakovana vrednost obstaja. Vedno je

$$M_X(0) \;=\; \mathbb{E}(1) \;=\; 1.$$

Za $t \neq 0$ je $y(x) = e^{tx}$ *zvezno odvedljiva* bijekcija $\mathbb{R} \to (0, \infty)$ in za slučajno spremenljivko X z gostoto f_X velja

$$M_X(t) \;=\; \sum_{k=0}^{\infty} \frac{1}{k!} t^k \mathbb{E}(X^k).$$

To pomeni, da je M_X *analitična*; porazdelitev slučajne spremenljivke X je *enolično* določena z momenti.

Trditev 6.3.

$$M_{aX+b}(t) \;=\; e^{tb} M_X(at)$$

Posledica.

$$M_{\mathcal{N}(\mu,\sigma^2)}(t) \;=\; M_{\sigma\cdot\mathcal{N}(0,1)+\mu}(t) \;=\; e^{t\mu} \cdot e^{\frac{(\sigma t)^2}{2}}$$

Trditev 6.4. Če sta slučajni spremenljivki X in Y *neodvisni*, velja

$$M_{X+Y}(t) \;=\; M_X(t) \cdot M_Y(t).$$

Lema 1. Če sta slučajni spremenljivki X in Y *neodvisni* in $f, g : \mathbb{R} \to \mathbb{R}$ (ali $f : (a,b) \to \mathbb{R}$, $g : (c,d) \to \mathbb{R}$) *zvezni* funkciji, potem sta $f(X)$ in $g(Y)$ neodvisni:

$$\begin{aligned}\mathbb{P}(f(X) \in \mathcal{B},\ g(Y) \in \mathcal{C}) \;&=\; \mathbb{P}(X \in f^{-1}(\mathcal{B}),\ Y \in g^{-1}(\mathcal{C})) \;= \\ &=\; \mathbb{P}(X \in f^{-1}(\mathcal{B})) \cdot \mathbb{P}(Y \in g^{-1}(\mathcal{C})),\end{aligned}$$

kjer smo pri zadnjem enačaju upoštevali *neodvisnost*.

7 LIMITNI IZREKI

Izrek 7.1 (Krepki zakon velikih števil)**.** Verjetnost tistih vzorcev $s = (\omega_1, \omega_2, \omega_3, \ldots) \in S$, za katere je

$$\lim_{n\to\infty} \frac{X(\omega_1) + \ldots + X(\omega_n)}{n} \;=\; \lim_{n\to\infty} \frac{X_1(s) + \ldots + X_n(s)}{n} \;=\; \mathbb{E}(x),$$

je enaka 1.

Trditev 7.1 (Markova neenakost)**.** Naj bo X slučajna spremenljivka s pričakovano vrednostjo in $a > 0$. Tedaj je

$$\mathbb{P}(|X| > a) \;\leq\; \frac{1}{|a|}\mathbb{E}(|X|).$$

Posledica (Čebiševa neenakost)**.** Naj bo $\mathbb{E}(X^2) < \infty$ in bo $\varepsilon > 0$. Tedaj je

$$\mathbb{P}(|X - \mathbb{E}(X)| > \varepsilon) \;=\; \frac{Var(X)}{\varepsilon^2}.$$

Izrek 7.2 (Šibki zakon velikih števil Markova)**.** Naj bodo $X_1, X_2, \ldots$ *neodvisne* in *enako porazdeljene* sličajne spremenljivka z varianco $\sigma^2 < \infty$ in pričakovano vrednostjo μ. Tedaj $\forall \varepsilon > 0$ velja

$$\lim_{n\to\infty} \mathbb{P}\left(\left|\frac{X_1 + \ldots + X_n}{n} - \mu\right| > \varepsilon\right) \;=\; 0.$$

Definicija 7.1. Naj bodo $Y, Y_1, Y_2, Y_3, \ldots$ slučajne spremenljivke, definirane na skupnem verjetnostnem prostoru. Pravimo, da zaporedje $\{Y_n\}_n$ *verjetnostno konvergira* k Y, pišemo $Y_n \xrightarrow[n\to\infty]{p} Y$, če $\forall \varepsilon > 0$ velja

$$\lim_{n\to\infty} \mathbb{P}(|Y_n - Y| > \varepsilon) \;=\; 0.$$

Komentar. Če so $X_1, X_2, \dots$ *neodvisne enako porazdeljene* slučajne spremenljivke s pričakovano vrednostjo μ in disperzijo σ^2, potem

$$\overline{X} \;=\; \frac{1}{n}\sum_{i=1}^{n} X_i \;\xrightarrow[n\to\infty]{p}\; \mu.$$

$\forall \varepsilon > 0:$

$$\lim_{n\to\infty} \mathbb{P}(|\overline{X} - \mu| > \varepsilon) \;=\; 0.$$

Definicija 7.2. Zaporedje $\{Y_n\}_n$ konvergira *skoraj gotovo* k Y, $Y_n \xrightarrow[n\to\infty]{s.g.} Y$, če je

$$\mathbb{P}(\lim_{n\to} Y_n = Y) \;=\; \mathbb{P}(\{s \mid \exists \lim_{n\to\infty} Y_n(s) = Y(s)\}) \;=\; 1.$$

Izrek 7.3 (Krepki zakon velikih števil Kolmogorova)**.** Naj bodo $X_1, X_2, \dots$ *neodvisne* in *enako porazdeljene* slučajne spremenljivke s pričakovano vrednostjo μ. Tedaj velja

$$\overline{X} \;=\; \frac{1}{n}\sum_{i=1}^{n} X_i \;\xrightarrow[n\to\infty]{s.g.}\; \mu.$$

Komentar.

- obstoj variance ni potreben
- za $X : \Omega \to \mathbb{R}$ smo konstruirali $X_i : \Omega^{\mathbb{N}} \to \mathbb{R}$

Trditev 7.2. Iz *skoraj gotove* konvergence sledi konvergenca v *verjetnosti.*

Trditev 7.3. Naj bo $g : \mathbb{R} \to \mathbb{R}$ *zvezna* funkcija:

(1) Če velja $Y_n \xrightarrow[n\to\infty]{s.g.} Y_n$, potem $g(Y_n) \xrightarrow[n\to\infty]{s.g.} g(Y)$.

(2) Če velja $Y_n \xrightarrow[n\to\infty]{p} Y_n$, potem $g(Y_n) \xrightarrow[n\to\infty]{p} g(Y)$.

Izrek 7.4 (Centralni limitni izrek)**.** Naj bo $X_1, X_2, \dots$ zaporedje *neodvisnih* in *enako porazdeljenih* slučajnih spremenljivk s pričakovano vrednostjo μ in varianco $\sigma^2 < \infty$. Tedaj $\forall x \in \mathbb{R}$:

$$\lim_{n\to\infty} \mathbb{P}\left(\frac{\frac{X_1+\ldots+X_n}{n} - \mu}{\frac{\sigma}{\sqrt{n}}} \leq x \right) \;=\; \Phi(x) \;=\; \mathbb{P}(\mathcal{N}(0,1) \leq x).$$

Komentar. $\frac{\frac{X_1+\ldots+X_n}{n}-\mu}{\frac{\sigma}{\sqrt{n}}} = \frac{\overline{X}-\mu}{\frac{\sigma}{\sqrt{n}}}$ je *standardizacija* od $\overline{X}$. Izjava *centralnega limitnega izreka* pravi, da *komulativne porazdelitvene funkcije* standardiziranih vzorčnih povprečij po točkah konvergirajo k komulativni porazdelitveni funkciji Φ. Za realni števili $a < b$ sledi

$$\lim_{n\to\infty} \mathbb{P}\left(\frac{\overline{X}-\mu}{\frac{\sigma}{\sqrt{n}}} \in (a,b] \right) \;=\; \mathbb{P}\left(\overline{X} \in (\underbrace{\mu + a\frac{\sigma}{\sqrt{n}}}_{c}, \underbrace{\mu + b\frac{\sigma}{\sqrt{n}}}_{d}] \right).$$

Torej:

$$\mathbb{P}(\overline{X} \in (c,d]) \;\approx\; \Phi\left(\frac{d-\mu}{\frac{\sigma}{\sqrt{n}}}\right) - \Phi\left(\frac{c-\mu}{\frac{\sigma}{\sqrt{n}}}\right) \;=\; F_{\mathcal{N}(\mu,\ \frac{\sigma^2}{n})}(d) \,-\, F_{\mathcal{N}(\mu,\ \frac{\sigma^2}{n})}(c)$$

oziroma

$$\mathbb{P}(\overline{X} \in (c,d]) \;\approx\; \mathbb{P}\left(\mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right) \in (c,d]\right) \quad \text{za velike } n.$$

Rečemo tudi

$$\overline{X} \mathrel{\dot\sim} \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$

Izrek 7.5 (Izrek o zveznosti)**.** Če za slučajne spremenljivke $Y_1, Y_2, \ldots$, ki imajo momentno-rodovne funkcije na nekem intervalu $(-\delta, \delta)$, $\delta > 0$, velja

$$\lim_{n\to\infty} M_{Y_n}(t) \;=\; e^{\frac{t^2}{2}} \;=\; M_{\mathcal{N}(0,1)}(t) \quad \forall t \in (-\delta, \delta),$$

potem $\forall x \in \mathbb{R}$ velja

$$\lim_{n\to\infty} \mathbb{P}(Y_n \leq x) \;=\; \Phi(x).$$

8 TOČKOVNO OCENJEVANJE

Definicija 8.1. Naj bo c realnoštevilska "karakteristika" proučevane porazdelitve[2]. Cenilka za c je funkcija slučajnega vzorca $T = T(X_1, \ldots, X_n)$, s katero ocenjujemo c. Cenilka je določena s funkcijo $T : \mathbb{R}^n \to \mathbb{R}$; za $T(X_1, \ldots, X_n) = \overline{X}$ je

$$T(x_1, \ldots, x_n) \;=\; \frac{1}{n}(x_1 + \ldots + x_n).$$

Cenilka T karakteristike c je *nepristranska*, če velja

$$\mathbb{E}(T(X_1, \ldots, X_n)) \;=\; c(X)$$

za vsako dopustno porazdelitev. Natančneje: za vsako dopustno porazdelitev (k.p.f.) $F \in \mathcal{F}$ in vsak vzorec $X_1, \ldots, X_n \overset{NEP}{\sim} F$ velja

$$\mathbb{E}(T(X_1, \ldots, X_n)) \;=\; c(F).$$

Definicija 8.2. Naj bosta U in V *nepristranski* cenilki za $c(X)$ v modelu $\mathcal{F}$. Tedaj ima U enakomerno manjšo varianco od V, če velja

$$\mathrm{Var}(U(X_1, \ldots, X_n)) \;\leq\; \mathrm{Var}(V(X_1, \ldots, X_n))$$

$\forall F \in \mathcal{F}$ in vsak vzorec $X_1, \ldots, X_n \overset{NEP}{\sim} F$.

Definicija 8.3. Zaporedje cenilk T_n za karakteristike c, je *dosledno* (*angl. consistent*), če $\forall F \in \mathcal{F}$ in vsako neskončno zaporedje $X_1, X_2, \ldots \overset{NEP}{\sim} F$ zaporedje $T_n(X_1, \ldots, X_n)$ konvergira h konstanti $c(F)$ verjetnostno.

Komentar. Če $X_1, X_2, \ldots$ generiramo kot *neodvisne* replikacije slučajne spremenljivke $X : \Omega \to \mathbb{R}$, lahko X_i razumemo kot funkcijo na prostoru neskončnih vzorcev

$$S \;=\; \Omega^{\mathbb{N}} \;=\; \{\text{neskončna zaporedje iz } \Omega\}.$$

[2] npr. $c = \mathbb{E}(X)$, $c = \mathrm{Var}(X)$, $c = \mathbb{P}(X \geq 2)$, ...

8.1 Metode za konstrukcijo cenilk

Metoda 1 (Metoda momentov)**.** Zanima nas karakteristika $c(X)$ proučevane slučajne spremenljivke $X : \Omega \to \mathbb{R}$ v nekem modelu. Če je $c(X)$ mogoče izraziti z momenti kot $c(X) = g(m_1, m_2, \ldots, m_2)$, potem $c(X)$ ocenjujemo s cenilko $\hat{c} = g(\hat{m}_1, \hat{m}_2, \ldots, \hat{m}_r)$. Če je g *zvezna*, je cenilka $\hat{c}$ *dosledna.* V praksi imamo najpogosteje parametrični model z vektorskim parametrom $\vartheta = (\vartheta_1, \ldots, \vartheta_r)$, kjer izrazimo

$$\begin{aligned} m_1 &= m_1(\vartheta_1, \ldots, \vartheta_r) \\ &\vdots \\ m_r &= m_r(\vartheta_1, \ldots, \vartheta_r) \end{aligned}$$

Privzemimo, da znamo zgornji sistem razrešiti na ϑ z vektorsko funkcijo $(\vartheta_1, \ldots, \vartheta_r) = (g_1(m_1, \ldots, m_r), \ldots, g_r(m_1, \ldots, m_r))$. Potem za ϑ vzamemo cenilko

$$\hat{\vartheta} = (g_1(\hat{m}_1, \ldots, \hat{m}_r), \ldots, g_r(\hat{m}_1, \ldots, \hat{m}_r)).$$

Že vemo: če je $g = (g_1, \ldots, g_r)$ *zvezna*, je $\hat{\vartheta}$ *dosledna.*

Metoda 2 (Metoda največjega verjetja)**.** Privzemimo parametrični model s prostorom parametrov $\Theta \subset \mathbb{R}^r$ in splošnim parametrom $\vartheta = (\vartheta_1, \ldots, \vartheta_r) \in \Theta$. Dalje privzemimo, da imajo dopustne porazdelitve verjetnostne funkcije (v diskretnem modelu) oz. gostote (v zveznem modelu) oblike

$$f(x;\ \vartheta) = f(x;\ \vartheta_1, \ldots, \vartheta_r).$$

Definicija 8.4. *Funkcija verjetja* za vzorec velikosti n je $L : \mathbb{R}^n \times \Theta \to [0, \infty)$,

$$L(x_1, \ldots, x_n;\ \vartheta) = f(x_1;\ \vartheta) \cdot \ldots \cdot f(x_n;\ \vartheta).$$

Kot funkcija vzorca $\vec{x} = (x_1, \ldots, x_n)$ je L gostota vektorja $(x_1, \ldots, x_n)$. V teoriji verjetja L pri danem $\vec{x}$ gledamo kot funkcijo parametra ϑ. Oceno za ϑ pri danem $\vec{x}$ po metodi najmanjših kvadratov je tak $\hat{\vartheta} \in \Theta$, pri katerem ima $L(\vec{x};\ \vartheta)$ maksimum, torej velja:

$$L(\vec{x};\ \hat{\vartheta}) = \max_{\vartheta \in \Theta} L(\vec{x};\ \vartheta).$$

Oceno $\hat{\vartheta}$ analitično tipično izračunamo z odvajanjem. Zaradi preprostosti raje odvajamo logaritemsko funkcijo verjetja:

$$\ln(L(\vec{x};\ \vartheta)) \ = \ \sum_{i=1}^{n} \ln f(x_i;\ \vartheta).$$

Stacionarne točke funkcije $\ln L$ imenujemo rešitve *enačb verjetja* (EV)

$$\frac{\partial}{\partial \vartheta_j}(\ln L) \ = \ 0, \quad 1 \leq j \leq n.$$

Definicija 8.5 (Cenilka največjega verjetja)**.** Če za vse možne (v diskretnem primeru) ali skoraj vse (v zveznem primeru) realizacije $\vec{x}$ slučajnega vektorja $\vec{X}$ obstaja ocena $\hat{\vartheta}(\vec{x})$ za ϑ po metodi največjega verjetja, to je

$$\max_{\vartheta \in \overline{\Theta}} L(\vec{x};\ \vartheta \ = \ L(\vec{x};\ \hat{\vartheta}(\vec{x})),$$

potem funkciji $\hat{\vartheta} : \mathbb{R}^n \to \overline{\Theta}$ pravimo *cenilka največjega verjetja* (CNV) za ϑ.

Opomba. Imamo parametrični model s parametričnim prostorom Θ.

- Množica "možnih" vrednosti se ne spreminja s ϑ.
- Za "skoraj vse vrednosti" se ne spreminja s ϑ: če je $D_{\hat{\vartheta}}$ definicijsko območje, mora veljati

  $$\mathbb{P}((X_1, \ldots, X_n) \in D_{\hat{\vartheta})} \ = \ 1$$

  za vsako dopustno porazdelitev, $\forall \vartheta$ in $\forall X_i \overset{NEP}{\sim} \vartheta$.

Izrek 8.1. Naj bodo gostote (verjetnostne funkcije) $f(\vec{x};\ \vartheta)$ *dvakrat zvezno parcialno odvedljive* na ϑ_j, naj bo $\{\vec{x} \mid f(\vec{x};\ \vartheta) > 0\}$ *neodvisna* od ϑ in naj veljajo še dodatni blagi regularnostni privzetki. ČE imajo (EV) enolične rešitve za vse dovoolj velike vzorce, ki jih označimo $\hat{\vartheta} = \hat{\vartheta}(x_1, \ldots, x_n)$, potem je $\hat{\vartheta}(x_1, \ldots, x_n)$ dosledno zaporedje cenilk za ϑ.

9 INTERVALSKO OCENJEVANJE

Definicija 9.1. Naj bo $c = c(X) = c(F_X)$ proučevana karakteristika slučajne spremenljivke X. Naj bo $\alpha \in (0,1)$ vnaprej podano ("majhno") in naj bo n velikost vzorca. Interval zaupanja za c stopnje zaupanja $1-\alpha$ je prireditev $\vec{X} = (X_1, \ldots, X_n) \mapsto [L(X_1, \ldots, X_n), U(X_1, \ldots, X_n)]$ za katero velja:

$$\mathbb{P}([L(X_1, \ldots, X_n), U(X_1, \ldots, X_n)] \ni c(F)) \ \geq \ 1-\alpha$$

za vsako dopustno porazdelitev F in $\forall X_1, \ldots, X_n \overset{NEP}{\sim} F$.

Komentar. Interval zaupanja je določen s funkcijama $L, U : \mathbb{R}^n \to \mathbb{R}$.

Metoda 3 (Intervali zaupanja v normalnih modelih)**.**

i) Interval zaupanja za μ pri *poznani* disperziji σ^2

$$X_1, \ldots, X_n \overset{NEP}{\sim} \mathcal{N}(\mu, \sigma^2) \quad \Longrightarrow \quad \frac{\overline{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim \mathcal{N}(0,1)$$

Privzemimo, da za $a < b$ $(a, b \in \mathbb{R})$ velja

$$\mathbb{P}(\mathcal{N}(0,1) \in [a,b]) \ = \ \Phi(b) - \Phi(a) \ = \ 1-\alpha.$$

Tedaj

$$\mathbb{P}\left(a \leq \frac{\overline{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \leq b\right) \ = \ 1-\alpha \quad \Longleftrightarrow \quad \mathbb{P}\left(\overline{X} - a\frac{\sigma}{\sqrt{n}} \geq \mu \geq \overline{X} - b\frac{\sigma}{\sqrt{n}}\right) \ = \ 1-\alpha.$$

To pomeni, da je $[\overline{X} - b\frac{\sigma}{\sqrt{n}}, \overline{X} - a\frac{\sigma}{\sqrt{n}}]$ interval zaupanja za μ stopnje zaupanja $1-\alpha$. Širina intervala znaša $(b-a)\frac{\sigma}{\sqrt{n}}$. Zaradi simetričnosti gostote $f_{\mathcal{N}(0,1)}$, je minimum dosežen pri $a = -b$.

$$\Longrightarrow \ \Phi(b) \ = \ \Phi(b_{\text{sim}}) \ = \ 1 - \frac{\alpha}{2} \quad \text{in} \quad b \ = \ \Phi^{-1}\left(1 - \frac{\alpha}{2}\right) \ =: \ z_{\frac{\alpha}{2}}$$

Standardni interval zaupanja je torej

$$\left[\overline{X} - z_{\frac{\alpha}{2}}\frac{\sigma}{\sqrt{n}}, \overline{X} + z_{\frac{\alpha}{2}}\frac{\sigma}{\sqrt{n}}\right].$$

ii) Interval zaupanja za μ z *neznano* disperzijo σ^2

Neznani σ^2 ocenimo s

$$S^2 \;=\; \frac{1}{n-1}\sum_{i=1}^{n}(X_i-\overline{X})^2.$$

Uporabimo Studentovo porazdelitev z $n-1$ prostorskimi stopnjami:

$$t_{n-1} \;=\; \frac{\overline{X}-\mu}{\frac{S}{\sqrt{n}}}.$$

Interval zaupanja za μ stopnje zaupanja $1-\alpha$

$$\left[\overline{X}-b\frac{S}{\sqrt{n}}, \overline{X}-a\frac{S}{\sqrt{n}}\right]$$

dobimo, če za $a<b$ velja

$$\mathbb{P}(t_{n-1}\in[a,b]) \;=\; F_{t_{n-1}}(b)-F_{t_{n-1}}(a) \;=\; 1-\alpha.$$

Ker je tudi t_{n-1} simetrična porazdelitev, minimum dosežemo pri

$$-a \;=\; b \;=\; F^{-1}_{t_{n-1}}(1-\frac{\alpha}{2}) \;=\; t_{n-1;\frac{\alpha}{2}}.$$

Standardni interval zaupanja:

$$\left[\overline{X}-t_{n-1;\frac{\alpha}{2}}\frac{S}{\sqrt{n}}, \overline{X}+t_{n-1;\frac{\alpha}{2}}\frac{S}{\sqrt{n}}\right].$$

iii) Interval zaupanja za σ^2 z *znano* pričakovano vrednostjo μ

Za $X_i \overset{NEP}{\sim} \mathcal{N}(\mu,\sigma^2)$ je

$$\sum_{i=1}^{n}\left(\frac{X_i-\mu}{\sigma}\right)^2 \;\sim\; \chi^2_n.$$

Če velja $\mathbb{P}(\chi^2_n\in[a,b])=1-\alpha$, je

$$\mathbb{P}\left(a\le\frac{1}{\sigma^2}\sum_{i=1}^{n}(X_i-\mu)^2\le b\right) \;=\; 1-\alpha$$

oziroma

$$\mathbb{P}\left(\left[\frac{1}{b}\sum_{i=1}^{n}(X_i-\mu)^2, \frac{1}{a}\sum_{i=1}^{n}(X_i-\mu)^2\right]\right) \;=\; 1-\alpha.$$

Širina dobljenega intervala je $\left(\frac{1}{a} - \frac{1}{b}\right) \sum_{i=1}^{n} (X_i - \mu)^2$, z minimizacijo dobimo $\frac{1}{a} - \frac{1}{b}$ pri vezi

$$\mathbb{P}(\chi_n^2 \in [a, b]) \;=\; F_{\chi_n^2}(b) - F_{\chi_n^2}(a) \;=\; 1 - \alpha.$$

Izrek 9.1 (Student, Fisher)**.** Naj bodo $X_1, \ldots, X_n \overset{NEP}{\sim} \mathcal{N}(\mu, \sigma^2)$. Tedaj sta

$$\overline{X} \;=\; \frac{1}{n}(X_1 + \ldots + X_n) \quad \text{in} \quad S^2 \;=\; \frac{1}{n-1} \sum_{i=1}^{n} (X_i - \overline{X})^2$$

neodvisni slučajni spremenljivki. Velja

$$\frac{n-1}{\sigma^2} \cdot S^2 \;=\; \sum_{i=1}^{n} \left(\frac{X_i - \overline{X}}{\sigma} \right)^2 \;\sim\; \chi_{n-1}^2 \;=\; \Gamma\left(\frac{n-1}{2}, \frac{1}{2} \right).$$

Definicija 9.2. Naj bosta Z in K *neodvisni* slučajni spremenljivki in $Z \sim \mathcal{N}(0, 1)$ ter $K \sim \chi_k^2$. Tedaj pravimo, da ima slučajna spremenljivka $\frac{Z}{\sqrt{\frac{K}{k}}}$ Studentovo porazdelitev s k prostorskimi stopnjami. Označimo jo s t_k.

Komentar. Porazdelitev t_k je zaradi *neodvisnosti* funkcija porazdelitve slučajne spremenljivke Z in slučajne spremenljivke K. Takoj sledi, da je t_k *simetrična* okrog 0. Očitno sta $\frac{Z}{\sqrt{\frac{K}{k}}}$ in $\frac{-Z}{\sqrt{\frac{K}{k}}}$ enako porazdeljeni.

Posledica. Slučajna spremenljivka

$$t \;=\; \frac{\overline{X} - \mu}{\frac{S}{\sqrt{n}}} \;\sim\; t_{n-1}$$

(tu je $S = \sqrt{S^2}$).

Metoda 4 (Naprej: Intervali zaupanja v normalnih modelih)**.**

iv) Interval zaupanja za σ^2 z *neznano* pričakovano vrednostjo μ

Za $X_i \overset{NEP}{\sim} \mathcal{N}(\mu, \sigma^2)$ je

$$\sum_{i=1}^{n} \left(\frac{X_i - \overline{X}}{\sigma} \right)^2 \;\sim\; \chi^2_{n-1}.$$

Če velja $\mathbb{P}(\chi^2_{n-1} \in [a, b]) = 1 - \alpha$, je

$$\mathbb{P}\left(a \leq \frac{1}{\sigma^2} \sum_{i=1}^{n} (X_i - \overline{X})^2 \leq b \right) \;=\; 1 - \alpha$$

oziroma

$$\mathbb{P}\left(\left[\frac{1}{b} \sum_{i=1}^{n} (X_i - \overline{X})^2, \frac{1}{a} \sum_{i=1}^{n} (X_i - \overline{X})^2 \right] \right) \;=\; 1 - \alpha.$$

Širina dobljenega intervala je $\left(\frac{1}{a} - \frac{1}{b} \right) \sum_{i=1}^{n} (X_i - \overline{X})^2$, z minimizacijo dobimo $\frac{1}{a} - \frac{1}{b}$ pri vezi

$$\mathbb{P}(\chi^2_{n-1} \in [a, b]) \;=\; F_{\chi^2_{n-1}}(b) - F_{\chi^2_{n-1}}(a) \;=\; 1 - \alpha.$$

10 PREIZKUŠANJE DOMNEV

Definicija 10.1. Statistična domneva (hipoteza) je izjava, da porazdelitev slučajne spremenljivke X pripada neki podmnožici $\mathcal{H} \subseteq \mathcal{F}$.

Definicija 10.2. Preizkus domneve $\mathcal{H}$ proti alternativi $\mathcal{A}$ za vzorec velikosti n je odločitveno pravilo, ki na podlagi realizacije n *neodvisnih* replikacij proučevane slučajne spremenljivke odloči, ali $\mathcal{H}$ zavrnemo (in s tem sprejmemo $\mathcal{A}$) ali je ne zavrnemo (oz. jo "sprejmemo").

Komentar. Verjetnost napake 1. vrste je funkcija, definirana na domnevi $\mathcal{H}$. Če je $\mathcal{H}$ sestavljena iz ene porazdelitve ("enostavna"), je to v resnici eno število.