

# Verjetnost in statistika - definicije, trditve in izreki

Oskar Vavtar  
po predavanjih profesorja Jaka Smrekarja

2020/21

## Kazalo

<b>1</b>	<b>SLUČAJNI VEKTORJI</b>	<b>3</b>
<b>2</b>	<b>NEODVISNOST</b>	<b>5</b>
<b>3</b>	<b>FUNKCIJE in TRANSFORMACIJE</b>	
	slučajnih spremenljivk in vektorjev	<b>6</b>
3.1	Slučajne spremenljivke . . . . .	6
3.2	Slučajni vektorji . . . . .	7
<b>4</b>	<b>PRIČAKOVANA VREDNOST</b>	
	zveznih slučajnih spremenljivk in vektorjev	<b>8</b>
4.1	Pričakovana vrednost funkcij slučajnih spremenljivk in vektorjev . . . . .	8
4.2	Disperzija, kovarianca in variančno-kovariančno matrika . . .	10
<b>5</b>	<b>POGOJNE PORAZDELITVE in</b>	
	<b>POGOJNA PRIČAKOVANA VREDNOST</b>	<b>13</b>
<b>6</b>	<b>MOMENTI in</b>	
	<b>MOMENTNO-RODOVNA FUNKCIJA</b>	<b>15</b>
<b>7</b>	<b>LIMITNI IZREKI</b>	<b>18</b>
<b>8</b>	<b>TOČKOVNO OCENJEVANJE</b>	<b>21</b>
8.1	Metode za konstrukcijo cenilk . . . . .	22
<b>9</b>	<b>INTERVALSKO OCENJEVANJE</b>	<b>24</b>
<b>10</b>	<b>PREIZKUŠANJE DOMNEV</b>	<b>26</b>

# 1 SLUČAJNI VEKTORJI

**Definicija 1.1** (Komulativna porazdelitvena funkcija). Slučajni vektor je taka funkcija/preslikava  $\vec{X} = (X_1, \dots, X_n) : \Omega \rightarrow \mathbb{R}^n$ , kjer je  $\Omega$  verjetnostni prostor, za katero so množice

$$\begin{aligned} \{X_1 \leq x_1, \dots, X_n \leq x_n\} &= \{X_1 \in (-\infty, x_1], \dots, X_n \in (-\infty, x_n]\} \\ &= \{\vec{X} \in (-\infty, x_1] \times \dots \times (-\infty, x_n]\} \\ &= \vec{X}^{-1}((-\infty, x_1] \times \dots \times (-\infty, x_n]) \end{aligned}$$

dogodki za vse *realne*  $n$ -terice  $(x_1, \dots, x_n) \in \mathbb{R}^n$ .

*Komulativna porazdelitvena funkcija* slučajnega vektorja  $\vec{X}$  je funkcija  $F_X : \mathbb{R}^n \rightarrow [0, 1]$  s predpisom

$$F_{\vec{X}}(x_1, \dots, x_n) = \mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n).$$

**Trditev 1.1** (Lastnosti KPF).

(1)

$$\begin{aligned} \lim_{x_i \rightarrow -\infty} F_{\vec{X}}(x_1, \dots, x_n) &= 0 \\ \lim_{\substack{x_1 \rightarrow \infty \\ \dots \\ x_n \rightarrow \infty}} F_{\vec{X}}(x_1, \dots, x_n) &= 1 \end{aligned}$$

(2) MONOTONOST:

Če je  $x_i \leq y_i$  za  $\forall i \in \{1, \dots, n\}$ , je

$$F_{\vec{X}}(x_1, \dots, x_n) = F_{\vec{X}}(\vec{x}) \leq F_{\vec{X}}(\vec{y}).$$

To sledi iz monotonosti  $\mathbb{P}$ .

(3) ZVEZNOST Z DESNE:

$$\lim_{\vec{y} \searrow \vec{x}} F_{\vec{X}}(\vec{y}) = F_{\vec{X}}(\vec{x})$$

Tu  $\vec{y} \searrow \vec{x}$  interpretiramo kot  $\vec{y}_i \searrow \vec{x}_i$  za  $\forall i$ .

**Opomba.** Lastnosti (1), (2) in (3) karakterizirajo družino abstraktnih komulativnih porazdelitvenih funkcij v primeru slučajnih spremenljivk ( $n = 1$ ). V večrazsežnem prostoru to ne drži.

**Izrek 1.1.** Če je  $F : \mathbb{R}^2 \rightarrow [0, 1]$  zadošča (1), (2), (3) in (4):

$$F(b, d) - F(a, d) - F(b, c) + F(a, c) \geq 0$$

za vse četverice  $a < b$  in  $c < d$ , je  $F$  *komulativna porazdelitvena funkcija* nekega slučajnega vektorja  $(X, Y) : \Omega \rightarrow \mathbb{R}^2$ .

**Definicija 1.2** (“Zvezni” slučajni vektorj). Slučajni vektor  $\vec{X} : \Omega \rightarrow \mathbb{R}^n$  ima (*zvezno*) gostoto, če obstaja taka *zvezna* funkcija  $f_{\vec{X}} : \mathbb{R}^n \rightarrow [0, \infty)$ , da zanjo velja

$$\mathbb{P}(\vec{x} \in \mathcal{B}) = \int_{\mathcal{B}} f_{\vec{X}}(x_1, \dots, x_n) dx_1 \dots dx_n,$$

za vsako Borelovo množico  $\mathcal{B} \subset \mathbb{R}^n$ .

**Posplošitev.** Pravimo, da ima vektor  $\vec{X} = (X_1, \dots, X_n)$   $n$ -razsežno normalno porazdelitev s parametrom  $\vec{\mu} \in \mathbb{R}$  in  $\Sigma \in \mathbb{R}^{n \times n}$  (*simetrična* in *pozitivno definitna*), če ima gostoto:

$$f_{\vec{X}}(\vec{x}) = (2\pi)^{-\frac{n}{2}} (\det \Sigma)^{-1} e^{-\frac{1}{2} \langle \Sigma^{-1}(\vec{x} - \vec{\mu}), (\vec{x} - \vec{\mu}) \rangle}$$

## 2 NEODVISNOST

**Definicija 2.1.** Komponente  $X_1, \dots, X_n$  slučajnega vektorja  $\vec{X} = (X_1, \dots, X_n)$  so *neodvisne*, če velja

$$F_{\vec{X}}(x_1, \dots, x_n) = F_{X_1}(x_1) \cdot \dots \cdot F_{X_n}(x_n)$$

za vse  $n$ -terice  $(x_1, \dots, x_n) \in \mathbb{R}^n$ .

**Opomba.** Enakost lahko prepišemo v

$$\mathbb{P}(\vec{X} \in (-\infty, x_1] \times \dots \times (-\infty, x_n]) = \mathbb{P}(X_1 \in (-\infty, x_1]) \cdot \dots \cdot \mathbb{P}(X_n \in (-\infty, x_n])$$

**Trditev 2.1.** Naj ima  $(X, Y)$  “*zvezno*” gostoto  $f(X, Y)$  in naj bosta  $f_X$  in  $f_Y$  robni gostoti. Tedaj sta  $X$  in  $Y$  *neodvisni* natanko takrat, ko

$$f_{(X,Y)}(x, y) = f_X(x) \cdot f_Y(y)$$

za skoraj vse pare  $x$  in  $y$ .

**Trditev 2.2** (Posledica prejšnje trditve). Naj ima  $(X, Y)$  “*zvezno*” gostoto  $f_{(X,Y)}(x, y)$ . Tedaj sta  $X$  in  $Y$  neodvisni natanko takrat, ko velja

$$f_{(X,Y)}(x, y) = \Phi(x)\Psi(y)$$

za skoraj vse  $x$  in  $y$ , za neki *nenegativni* integralski funkciji.

### 3 FUNKCIJE in TRANSFORMACIJE slučajnih spremenljivk in vektorjev

#### 3.1 Slučajne spremenljivke

**Trditev 3.1** (Diskretni primer). Če je  $X$  *diskretna slučajna spremenljivka* z vrednostmi  $\{x_i \mid i \in I\}$  in je  $g$  funkcija, ki preslika množico  $\{x_i \mid i \in I\}$  na množico  $\{y_j \mid j \in J\}$ , je  $g \circ X = g(X)$  *diskretna slučajna spremenljivka* z verjetnostno funkcijo

$$\mathbb{P}(g(X) = y_j) = \sum_{i: g(x_i)=y_j} \mathbb{P}(X = x_i)$$

**Trditev 3.2** (Zvezni primer). Naj ima slučajna spremenljivka  $X$  “zvezno” gostoto  $f_X$ , ki je različna od 0 natanko na intervalu  $(a, b)$ , kjer  $-\infty \leq a \leq b \leq \infty$ .

Naj bo  $g : (a, b) \rightarrow (c, d)$  *zvezna bijekcija*. Zanima nas funkcija  $g(X)$  slučajne spremenljivke  $X$ .

Velja tudi

$$\mathbb{P}(X \in (a, b)) = \int_a^b f_X(x) dx = \int_{\mathbb{R}} f_X(x) dx = 1.$$

Velja  $\{g(X) \leq z\} = \{X \leq g^{-1}(z)\}$ . Ker je  $X$  slučajna spremenljivka, so  $\{X \leq g^{-1}(z)\}$  dogodki za  $z \in (c, d)$ . Sledi, da je  $g(X)$  slučajna spremenljivka in velja:

$$F_{g(X)}(z) = \mathbb{P}(g(X) \leq z) = \begin{cases} 1 & ; \quad z \geq d \\ F_X(g^{-1}(z)) & ; \quad z \in (c, d) \\ 0 & ; \quad z \leq c \end{cases}$$

Če je  $g$  *odvedljiva*, sledi:

$$f_{g(X)}(z) = \frac{d}{dz} F_{g(X)}(z) = \begin{cases} \frac{f_X(g^{-1}(z))}{g'(g^{-1}(z))} & ; \quad z \in (c, d) \\ 0 & ; \quad \text{sicer} \end{cases}$$

Za splošno *odvedljivo bijekcijo*  $g : (a, b) \rightarrow (c, d)$  velja t.i. *transformacijska formula*:

$$f_{g(X)}(z) = \frac{f_X(g^{-1}(z))}{|g'(g^{-1}(z))|}, \quad \text{za } z \in (c, d).$$

### 3.2 Slučajni vektorji

**Trditev 3.3.** Naj bo  $\vec{X} : \Omega \rightarrow \mathbb{R}^n$  slučajni vektor in naj bo  $h : \mathbb{R}^n \rightarrow \mathbb{R}$  zvezna funkcija. Tedaj je  $h(\vec{X}) = h(X_1, \dots, X_n)$  slučajna spremenljivka.

**Trditev 3.4.** Naj bo  $\vec{X} : \Omega \rightarrow \mathbb{R}^n$  slučajni vektor z gostoto  $f_{\vec{X}}$ . Dalje naj bo  $g : \mathbb{R}^n \rightarrow \mathbb{R}^n$  (ali  $g : D \rightarrow E$  za primerni množici  $D, E \subset \mathbb{R}^n$ , kjer  $\mathbb{P}(\vec{X} \in D) = 1$ ) zvezno diferenciablena bijekcija. Tedaj ima slučajni vektor  $g(\vec{X})$  gostoto

$$f_{g(\vec{X})}(\vec{z}) = f_{\vec{X}}(g^{-1}(\vec{z})) \cdot |\det Jg^{-1}(\vec{z})|$$

v točkah  $\vec{z} \in \mathbb{R}^n$  (oz.  $\vec{z} \in E$ ).

Za dvorazsežne vektorje, kjer je  $\vec{z} = (u, v)$  in  $(U, V) = g(X, Y)$  ter posledično  $(X, Y) = g^{-1}(U, V)$  se transformacijska formula glasi

$$f_{(U,V)}(u, v) = f_{(X,Y)}(g^{-1}(u, v)) \cdot |\det Jg^{-1}(u, v)|$$

oziroma

$$f_{(U,V)}(u, v) = f_{(X,Y)}(x(u, v), y(u, v)) \cdot \left\| \begin{pmatrix} \frac{\partial x}{\partial u} & \frac{\partial x}{\partial v} \\ \frac{\partial y}{\partial u} & \frac{\partial y}{\partial v} \end{pmatrix} \right\|.$$

Upošteva se  $g \circ g^{-1} = \text{id}$  in posledično

$$Jg(g^{-1}(u, v)) \cdot Jg^{-1}(u, v) = I$$

zgornje prepišemo v

$$f_{(U,V)}(u, v) = \frac{f_{(X,Y)}(g^{-1}(u, v))}{|\det Jg(g^{-1}(u, v))|} = \frac{f_{(X,Y)}(x(u, v), y(u, v))}{\left\| \begin{pmatrix} \frac{\partial u}{\partial x} & \frac{\partial u}{\partial y} \\ \frac{\partial v}{\partial x} & \frac{\partial v}{\partial y} \end{pmatrix} \right\|_{(x(u,v), y(u,v))}}.$$

**Trditev 3.5.** Naj za  $\vec{X} : \Omega \rightarrow \mathbb{R}^n$  velja  $\vec{X} \sim N(\vec{\mu}, \Sigma)$  in naj bo  $A : \mathbb{R}^n \rightarrow \mathbb{R}^n$  obrnljiva matrika. Dalje naj bo  $\vec{v} \in \mathbb{R}^n$ . Tedaj

$$A\vec{X} + \vec{v} \sim \mathcal{N}(A\vec{\mu} + \vec{v}, A\Sigma A^T).$$

## 4 PRIČAKOVANA VREDNOST zveznih slučajnih spremenljivk in vektorjev

**Definicija 4.1.** Naj bo  $X$  slučajna spremenljivka z “zvezno” gostoto  $f_X : \mathbb{R} \rightarrow [0, \infty)$ . *Pričakovana vrednost* slučajne spremenljivke  $X$  je

$$\mathbb{E}(X) = \int_{-\infty}^{\infty} x \cdot f_X dx,$$

če integral absolutno konvergira.

Za slučajni vektor  $\vec{X} = (X_1, \dots, X_n)$  definiramo pričakovano vrednost po komponentah

$$\mathbb{E}(\vec{X}) = (\mathbb{E}(X_1), \dots, \mathbb{E}(X_n)) \in \mathbb{R}^n.$$

Podobno definiramo tudi pričakovano vrednost slučajnih matrik.

### 4.1 Pričakovana vrednost funkcij slučajnih spremenljivk in vektorjev

**Trditev 4.1.** Naj bo  $g : \mathbb{R} \rightarrow \mathbb{R}$  (ali  $g : (a, b) \rightarrow (c, d)$ ) zvezna funkcija. Tedaj je

$$\mathbb{E}(g(X)) = \int_{-\infty}^{\infty} g(x) f_X(x) dx,$$

če obstaja.

**Posledica.** Za  $p \neq 0$  velja:

$$\mathbb{E}(|x|^p) = \int_0^{\infty} |z|^p (f_X(z) + f_X(-z)) dz = \dots = \int_{-\infty}^{\infty} |x|^p f_X(x) dx.$$



**Trditev 4.2.** Naj bo  $h : \mathbb{R}^2 \rightarrow \mathbb{R}$  (oziroma  $h : D \rightarrow \mathbb{R}$  v primeru, da  $\mathbb{P}((X, Y) \in D) = 1$ ) *zvezna* funkcija in  $(X, Y)$  slučajni vektor z gostoto  $f_{(X, Y)}$ . Tedaj velja

$$\mathbb{E}(h(X, Y)) = \int_{\mathbb{R}^2 \text{ (ali } D)} h(x, y) f_{(X, Y)}(x, y) dx dy,$$

če obstaja.

**Posledica.**

$$\mathbb{E}(XY) = \int_{\mathbb{R}} x \cdot y \cdot f_{(X, Y)}(x, y) dx dy,$$

če integral absolutno konvergira.

**Opomba.** Če sta  $X$  in  $Y$  *neodvisni* slučajni spremenljivki, za kateri obstajata  $\mathbb{E}(X)$  in  $\mathbb{E}(Y)$ , potem obstaja  $\mathbb{E}(XY)$  in je

$$\mathbb{E}(XY) = \mathbb{E}(X) \cdot \mathbb{E}(Y).$$

**Posledica** (Aditivnosti pričakovane vrednosti). Če je  $X \leq Y$  (z verjetnostjo 1), velja

$$\mathbb{E}(X) \leq \mathbb{E}(Y)$$

če  $\mathbb{E}(|Y|) < \infty$ .

**Izrek 4.1.** Naj za slučajni spremenljivki  $X$  in  $Y$  velja  $\mathbb{E}(X^2) < \infty$  in  $\mathbb{E}(Y^2) < \infty$ . Tedaj obstaja  $\mathbb{E}(XY)$  in velja

$$\mathbb{E}(|XY|) \leq \sqrt{\mathbb{E}(X^2)\mathbb{E}(Y^2)}.$$

$$\text{Enakost nastopi} \iff \frac{Y}{\sqrt{\mathbb{E}(Y^2)}} = \pm \frac{X}{\sqrt{\mathbb{E}(X^2)}} \text{ skoraj gotovo.}$$

**Posledica.** Če je  $\mathbb{E}(X^2) < \infty$ , je  $\mathbb{E}(|X|) < \infty$  in

$$\mathbb{E}(|X|) \leq \sqrt{\mathbb{E}(X^2)}.$$

## 4.2 Disperzija, kovarianca in variančno-kovariančno matrika

**Definicija 4.2.** *Disperzija (razpršenost, varianca)* slučajne spremenljivke  $X$  je

$$\mathbb{E}((X - \mathbb{E}(X))^2),$$

če ta pričakovana vrednost obstaja. Ta obstaja, če obstaja  $\mathbb{E}(X^2)$  in tedaj velja

$$\text{Var}(X) = \mathbb{E}(X^2) - \mathbb{E}(X)^2.$$

**Definicija 4.3.** *Standardni odklon* slučajne spremenljivke  $X$  definiramo kot

$$\sigma(X) = \sigma_X = \sqrt{\text{Var}(X)}.$$

Pripomnimo, da ima  $\sigma(X)$  iste enote kot  $X$  in je zato  $\sigma(X)$  “količina” ki je neposredno primerljiva z  $X$ .

**Trditev 4.3** (Lastnosti variance). Naj za slučajno spremenljivko  $X$  obstaja  $\mathbb{E}(X^2)$  (torej obstaja tudi  $\text{Var}(X)$ ):

- $\text{Var}(X) \geq 0$  in  $\text{Var}(X) = 0 \iff X \equiv \mathbb{E}(X)$  skoraj gotovo,
- $\text{Var}(X)$  je minimum funkcije  $a \mapsto \mathbb{E}((X - a)^2)$ ,
- $\text{Var}(aX + b) = a^2 \text{Var}(X)$ ,
- $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$ , če sta  $X$  in  $Y$  neodvisni.

**Komentar.** Vemo, da je  $\sigma^2$  v  $\mathcal{N}(\mu, \sigma^2)$  disperzija.

**Opomba.** Za *zvezno* slučajno spremenljivko  $X$  z gostoto  $f_X$  je

$$\text{Var}(X) = \int_{-\infty}^{\infty} (x - \mathbb{E}(X))^2 f_X(x) dx.$$

**Definicija 4.4.** Kovarianca slučajnih spremenljivk  $X$  in  $Y$  je

$$Cov(X, Y) = \mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y))),$$

če obstaja.  $Cov(X, Y)$  obstaja, če obstajajo  $\mathbb{E}(X)$ ,  $\mathbb{E}(Y)$ ,  $\mathbb{E}(XY)$ . Če je tako, velja

$$Cov(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y).$$

Če sta  $X$  in  $Y$  neodvisni in imata pričakovano vrednost, potem

$$Cov(X, Y) = 0.$$

**Trditev 4.4** (Lastnosti kovariance).

- $Cov(X, Y)$  obstaja, če obstajata  $Var(X)$  in  $Var(Y)$  ter velja *Cauchy-Schwarzova neenakost*

$$|Cov(X, Y)| \leq \sqrt{Var(X)Var(Y)} = \sigma(X)\sigma(Y),$$

enakost nastopi  $\iff \frac{Y - \mathbb{E}(Y)}{\sigma(Y)} = \pm \frac{X - \mathbb{E}(X)}{\sigma(X)}$  skoraj gotovo. V tem primeru pravimo, da sta  $X$  in  $Y$  skoraj gotovo linearno povezani.

- $Cov(X, X) = Var(X)$
- Kovarianca je *simetrična bilinearna* funkcija. Dovolj je preveriti bilinearnost v eni spremenljivki.
- Če ima  $(X, Y)$  zvezno gostoto  $f_{X,Y}$ , potem je

$$Cov(X, Y) = \iint_{\mathbb{R}^2} (x - \mathbb{E}(X))(y - \mathbb{E}(Y))f_{(X,Y)}(x, y) dx dy.$$

- Če imata  $X$  in  $Y$  disperzijo, jo ima tudi  $X + Y$  in velja

$$Var(X + Y) = Var(X) + 2Cov(X, Y) + Var(Y).$$

Posplošitev na disperzijo vrste  $X_1 + \dots + X_n$ :

$$Var(X_1 + \dots + X_n) = \sum_{i=1}^n Var(X_i) + 2 \sum_{1 \leq i < j \leq n} Cov(X_i, X_j)$$

**Definicija 4.5.** *Variančno-kovariančna matrika* slučajnega vektorja  $\vec{X} = (X_1, \dots, X_n)$  je matrika  $Var(\vec{X}) \in \mathbb{R}^{n \times n}$  z elementi

$$[Var(\vec{X})]_{ij} = Cov(X_i, X_j).$$

To je *simetrična* matrika z diagonalnimi elementi  $Var(X_1), \dots, Var(X_n)$ .

**Definicija 4.6.** *Pearsonov korelacijski koeficient* slučajnih spremenljivk  $X$  in  $Y$  z disperzijo je

$$\rho(X, Y) = \frac{Cov(X, Y)}{\sigma(X)\sigma(Y)} \in [-1, 1].$$

**Definicija 4.7.** Slučajni spremenljivki  $X$  in  $Y$  sta *nekorelirani* natanko takrat, ko

$$\mathbb{E}(XY) = \mathbb{E}(X)\mathbb{E}(Y).$$

Vidimo:

- Če sta  $X$  in  $Y$  *neodvisni* slučajni spremenljivki s pričakovano vrednostjo, sta *nekorelirani*.
- Obrat v splošnem ne drži, drži pa v primeru dvorazsežne normalno porazdeljenega slučajnega vektorja.
- Če imata  $X$  in  $Y$  disperzijo, sta nekorelirani  $\iff \rho(X, Y) = 0$ .

## 5 POGOJNE PORAZDELITVE in POGOJNA PRIČAKOVANA VREDNOST

**Definicija 5.1.** Naj bo  $\mathcal{B} \subseteq \mathbb{R}$  Borelova množica. Pogojna verjetnost, da  $Y$  zavzame vrednost v  $\mathcal{B}$  pri pogoju  $X = x$  je

$$\begin{aligned}\mathbb{P}(Y \in \mathcal{B} \mid X = x) &= \lim_{h \searrow 0} \mathbb{P}(Y \in \mathcal{B} \mid X \in (x - h, x + h)) = \\ &= \lim_{h \searrow 0} \frac{\mathbb{P}(Y \in \mathcal{B}, X \in (x - h, x + h))}{\mathbb{P}(X \in (x - h, x + h))},\end{aligned}$$

če ta limita obstaja.

**Trditev 5.1.** Naj ima  $(X, Y)$  “zvezno” gostoto  $f_{(X,Y)}$  in naj bo  $f_X(x)$  zvezna v  $x$ . Tedaj je

$$\mathbb{P}(Y \in \mathcal{B} \mid X = x) = \int_{\mathcal{B}} \frac{f_{(X,Y)}(x, y)}{f_X(x)} dy.$$

**Opomba.** Če sta  $X, Y$  neodvisni, je

$$f_{(Y|X)}(y \mid x) = f_Y(y).$$

Brez privzetka zveznosti je

$$\mathbb{P}(Y \in \mathcal{B} \mid X = x) = \mathbb{P}(Y \in \mathcal{B}).$$

**Trditev 5.2.** Velja tako imenovani zakon popolne verjetnosti:

$$\mathbb{P}(Y \in \mathcal{B}) = \int_{-\infty}^{\infty} \mathbb{P}(Y \in \mathcal{B} \mid X = x) f_X(x) dx.$$

**Definicija 5.2.** Pogojna pričakovana vrednost  $Y$ , pogojna na  $X = x$ , je pričakovana vrednost pogojne porazdelitve  $(Y \mid X = x)$ . V primeru, ko ima  $(X, Y)$  “zvezno” gostoto, to pomeni

$$\mathbb{E}(Y \mid X = x) = \int_{-\infty}^{\infty} y \cdot f_{(Y|X)}(y \mid x) dy.$$

**Trditev 5.3.** Zakon *popolne pričakovane vrednosti*:

$$\mathbb{E}(Y) = \int_{-\infty}^{\infty} \mathbb{E}(Y \mid X = x) f_X(x) dx.$$

**Komentar.** Velja tudi:

$$\begin{aligned} \mathbb{E}(g(Y) \mid X = x) &= \int_{-\infty}^{\infty} g(y) f_{(Y \mid X)}(y \mid x) dy \\ \text{in} \quad \mathbb{E}(g(Y)) &= \int_{-\infty}^{\infty} \mathbb{E}(g(Y) \mid X = x) f_X(x) dx. \end{aligned}$$

**Definicija 5.3.** Pogojna pričakovana vrednost  $\mathbb{E}(Y \mid X)$  je slučajna spremenljivka, definirana<sup>1</sup> kot:

$$\mathbb{E}(Y \mid X)(\omega) = \mathbb{E}(Y \mid X = X(\omega)).$$

Če pišemo  $g(x) = \mathbb{E}(Y \mid X = x)$ , je  $\mathbb{E}(Y \mid X) = g(X)$  *transformacija* slučajne spremenljivke  $X$ .

Sledi:

$$\begin{aligned} \mathbb{E}(\mathbb{E}(Y \mid X)) &= \mathbb{E}(g(X)) = \int_{-\infty}^{\infty} g(y) f_X(x) dx = \\ &= \int_{-\infty}^{\infty} \mathbb{E}(Y \mid X = x) f_X(x) dx = \mathbb{E}(Y). \end{aligned}$$

Pravimo, da je  $\mathbb{E}(Y \mid X)$  najboljši približek za  $Y$ , če poznamo  $X$ .

---

<sup>1</sup>Na istem verjetnostnem prostoru.

## 6 MOMENTI in MOMENTNO-RODOVNA FUNKCIJA

**Definicija 6.1.** Naj bo  $X$  slučajna spremenljivka in naj bosta  $k \in \mathbb{N}$  in  $a \in \mathbb{R}$ . Moment slučajne spremenljivke  $X$  glede na  $a$  je

$$m_k(a) = \mathbb{E}((X - a)^k),$$

če obstaja, torej če  $\mathbb{E}(|X - a|^k) < \infty$ .

V zveznem primeru je

$$m_k(a) = \int_{-\infty}^{\infty} (x - a)^k f(x) dx,$$

če integral absolutno konvergira.

Pravimo:

- $m_k(0) \dots k$ -ti *začetni* moment
- $m_k(\mathbb{E}(X)) \dots k$ -ti *centralni* moment

**Trditev 6.1.** Če obstaja  $m_n(a)$ , potem obstajajo  $m_k(a)$  za  $k < n$ .

**Trditev 6.2.** Če obstaja  $m_n(a)$  za neki  $a \in \mathbb{R}$ , obstaja  $m_n(b)$  za  $b \in \mathbb{R}$ .

**Posledica.** Če  $m_n$  obstaja, je

$$m_n(b) = \sum_{k=0}^n \binom{n}{k} (a - b)^{n-k} m_k(a).$$

**Izrek 6.1.** Naj obstajajo vsi momenti  $m_k = \mathbb{E}(X^k)$  in naj vrsta

$$\sum_{k=0}^{\infty} \frac{1}{k!} t^k \mathbb{E}(X^k)$$

absolutno konvergira za neki  $t > 0$ . Potem je porazdelitev slučajne spremenljivke  $X$  enolično določena z momenti. Če ima  $Y$  enako lastnost in velja

$$\mathbb{E}(X^k) = \mathbb{E}(Y^k) \quad \forall k,$$

sta  $X$  in  $Y$  enako porazdeljeni.

**Komentar.** To pomeni, da je komulativna porazdelitvena funkcija  $F_X : \mathbb{R} \rightarrow [0, 1]$  določena s *števnim* naborom števil.

**Definicija 6.2.** *Momentno-rodovna funkcija* slučajne spremenljivke  $X$  je funkcija

$$M_X(t) = \mathbb{E}(e^{tX}),$$

ki je definirana za tista realna števila  $t \in \mathbb{R}$ , za katera pričakovana vrednost obstaja. Vedno je

$$M_X(0) = \mathbb{E}(1) = 1.$$

Za  $t \neq 0$  je  $y(x) = e^{tx}$  zvezno odvedljiva bijekcija  $\mathbb{R} \rightarrow (0, \infty)$  in za slučajno spremenljivko  $X$  z gostoto  $f_X$  velja

$$M_X(t) = \sum_{k=0}^{\infty} \frac{1}{k!} t^k \mathbb{E}(X^k).$$

To pomeni, da je  $M_X$  *analitična*; porazdelitev slučajne spremenljivke  $X$  je *enolično* določena z momenti.

**Trditev 6.3.**

$$M_{aX+b}(t) = e^{tb} M_X(at)$$

**Posledica.**

$$M_{\mathcal{N}(\mu, \sigma^2)}(t) = M_{\sigma \cdot \mathcal{N}(0, 1) + \mu}(t) = e^{t\mu} \cdot e^{\frac{(\sigma t)^2}{2}}$$



**Trditev 6.4.** Če sta slučajni spremenljivki  $X$  in  $Y$  *neodvisni*, velja

$$M_{X+Y}(t) = M_X(t) \cdot M_Y(t).$$

**Lema 1.** Če sta slučajni spremenljivki  $X$  in  $Y$  *neodvisni* in  $f, g : \mathbb{R} \rightarrow \mathbb{R}$  (ali  $f : (a, b) \rightarrow \mathbb{R}$ ,  $g : (c, d) \rightarrow \mathbb{R}$ ) *zvezni* funkciji, potem sta  $f(X)$  in  $g(Y)$  neodvisni:

$$\begin{aligned} \mathbb{P}(f(X) \in \mathcal{B}, g(Y) \in \mathcal{C}) &= \mathbb{P}(X \in f^{-1}(\mathcal{B}), Y \in g^{-1}(\mathcal{C})) = \\ &= \mathbb{P}(X \in f^{-1}(\mathcal{B})) \cdot \mathbb{P}(Y \in g^{-1}(\mathcal{C})), \end{aligned}$$

kjer smo pri zadnjem enačanju upoštevali *neodvisnost*.

## 7 LIMITNI IZREKI

**Izrek 7.1** (Krepki zakon velikih števil). Verjetnost tistih vzorcev  $s = (\omega_1, \omega_2, \omega_3, \dots) \in S$ , za katere je

$$\lim_{n \rightarrow \infty} \frac{X(\omega_1) + \dots + X(\omega_n)}{n} = \lim_{n \rightarrow \infty} \frac{X_1(s) + \dots + X_n(s)}{n} = \mathbb{E}(x),$$

je enaka 1.

**Trditev 7.1** (Markova neenakost). Naj bo  $X$  slučajna spremenljivka s pričakovano vrednostjo in  $a > 0$ . Tedaj je

$$\mathbb{P}(|X| > a) \leq \frac{1}{|a|} \mathbb{E}(|X|).$$

**Posledica** (Čebiševa neenakost). Naj bo  $\mathbb{E}(X^2) < \infty$  in bo  $\varepsilon > 0$ . Tedaj je

$$\mathbb{P}(|X - \mathbb{E}(X)| > \varepsilon) = \frac{\text{Var}(X)}{\varepsilon^2}.$$

**Izrek 7.2** (Šibki zakon velikih števil Markova). Naj bodo  $X_1, X_2, \dots$  neodvisne in enako porazdeljene sličajne spremenljivke z varianco  $\sigma^2 < \infty$  in pričakovano vrednostjo  $\mu$ . Tedaj  $\forall \varepsilon > 0$  velja

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(\left|\frac{X_1 + \dots + X_n}{n} - \mu\right| > \varepsilon\right) = 0.$$

**Definicija 7.1.** Naj bodo  $Y, Y_1, Y_2, Y_3, \dots$  slučajne spremenljivke, definirane na skupnem verjetnostnem prostoru. Pravimo, da zaporedje  $\{Y_n\}_n$  verjetnostno konvergira k  $Y$ , pišemo  $Y_n \xrightarrow[n \rightarrow \infty]{p} Y$ , če  $\forall \varepsilon > 0$  velja

$$\lim_{n \rightarrow \infty} \mathbb{P}(|Y_n - Y| > \varepsilon) = 0.$$

**Komentar.** Če so  $X_1, X_2, \dots$  neodvisne enako porazdeljene slučajne spremenljivke s pričakovano vrednostjo  $\mu$  in disperzijo  $\sigma^2$ , potem

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow[n \rightarrow \infty]{p} \mu.$$

$\forall \varepsilon > 0 :$

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\bar{X} - \mu| > \varepsilon) = 0.$$

**Definicija 7.2.** Zaporedje  $\{Y_n\}_n$  konvergira *skoraj gotovo* k  $Y$ ,  $Y_n \xrightarrow[n \rightarrow \infty]{s.g.} Y$ , če je

$$\mathbb{P}(\lim_{n \rightarrow \infty} Y_n = Y) = \mathbb{P}(\{s \mid \exists \lim_{n \rightarrow \infty} Y_n(s) = Y(s)\}) = 1.$$

**Izrek 7.3** (Krepki zakon velikih števil Kolmogorova). Naj bodo  $X_1, X_2, \dots$  neodvisne in enako porazdeljene slučajne spremenljivke s pričakovano vrednostjo  $\mu$ . Tedaj velja

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow[n \rightarrow \infty]{s.g.} \mu.$$

**Komentar.** • obstoj variance ni potreben

- za  $X : \Omega \rightarrow \mathbb{R}$  smo konstruirali  $X_i : \Omega^{\mathbb{N}} \rightarrow \mathbb{R}$

**Trditev 7.2.** Iz *skoraj gotove* konvergence sledi konvergenca v *verjetnosti*.

**Trditev 7.3.** Naj bo  $g : \mathbb{R} \rightarrow \mathbb{R}$  zvezna funkcija:

- (1) Če velja  $Y_n \xrightarrow[n \rightarrow \infty]{s.g.} Y$ , potem  $g(Y_n) \xrightarrow[n \rightarrow \infty]{s.g.} g(Y)$ .
- (2) Če velja  $Y_n \xrightarrow[n \rightarrow \infty]{p} Y$ , potem  $g(Y_n) \xrightarrow[n \rightarrow \infty]{p} g(Y)$ .

**Izrek 7.4** (Centralni limitni izrek). Naj bo  $X_1, X_2, \dots$  zaporedje *neodvisnih* in *enako porazdeljenih* slučajnih spremenljivk s pričakovano vrednostjo  $\mu$  in varianco  $\sigma^2 < \infty$ . Tedaj  $\forall x \in \mathbb{R}$ :

$$\lim_{n \rightarrow \infty} \mathbb{P} \left( \frac{\frac{X_1 + \dots + X_n}{n} - \mu}{\frac{\sigma}{\sqrt{n}}} \leq x \right) = \Phi(x) = \mathbb{P}(\mathcal{N}(0, 1) \leq x).$$

**Komentar.**  $\frac{\frac{X_1 + \dots + X_n}{n} - \mu}{\frac{\sigma}{\sqrt{n}}} = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}}$  je *standardizacija* od  $\bar{X}$ . Izjava *centralnega limitnega izreka* pravi, da *komulativne porazdelitvene funkcije* standardiziranih vzorčnih povprečij po točkah konvergirajo k komulativni porazdelitveni funkciji  $\Phi$ . Za realni števili  $a < b$  sledi

$$\lim_{n \rightarrow \infty} \mathbb{P} \left( \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \in (a, b] \right) = \mathbb{P} \left( \bar{X} \in \underbrace{\left( \mu + a \frac{\sigma}{\sqrt{n}}, \mu + b \frac{\sigma}{\sqrt{n}} \right]}_c \right).$$

Torej:

$$\mathbb{P}(\bar{X} \in (c, d]) \approx \Phi \left( \frac{d - \mu}{\frac{\sigma}{\sqrt{n}}} \right) - \Phi \left( \frac{c - \mu}{\frac{\sigma}{\sqrt{n}}} \right) = F_{\mathcal{N}(\mu, \frac{\sigma^2}{n})}(d) - F_{\mathcal{N}(\mu, \frac{\sigma^2}{n})}(c)$$

oziroma

$$\mathbb{P}(\bar{X} \in (c, d]) \approx \mathbb{P} \left( \mathcal{N} \left( \mu, \frac{\sigma^2}{n} \right) \in (c, d] \right) \quad \text{za velike } n.$$

Rečemo tudi

$$\bar{X} \sim \mathcal{N} \left( \mu, \frac{\sigma^2}{n} \right).$$

**Izrek 7.5** (Izrek o zveznosti). Če za slučajne spremenljivke  $Y_1, Y_2, \dots$ , ki imajo momentno-rodovne funkcije na nekem intervalu  $(-\delta, \delta)$ ,  $\delta > 0$ , velja

$$\lim_{n \rightarrow \infty} M_{Y_n}(t) = e^{\frac{t^2}{2}} = M_{\mathcal{N}(0,1)}(t) \quad \forall t \in (-\delta, \delta),$$

potem  $\forall x \in \mathbb{R}$  velja

$$\lim_{n \rightarrow \infty} \mathbb{P}(Y_n \leq x) = \Phi(x).$$

## 8 TOČKOVNO OCENJEVANJE

**Definicija 8.1.** Naj bo  $c$  realnoštevilska “karakteristika” proučevane porazdelitve<sup>2</sup>. Cenilka za  $c$  je funkcija slučajnega vzorca  $T = T(X_1, \dots, X_n)$ , s katero ocenjujemo  $c$ . Cenilka je določena s funkcijo  $T : \mathbb{R}^n \rightarrow \mathbb{R}$ ; za  $T(X_1, \dots, X_n) = \bar{X}$  je

$$T(x_1, \dots, x_n) = \frac{1}{n}(x_1 + \dots + x_n).$$

Cenilka  $T$  karakteristike  $c$  je *nepristranska*, če velja

$$\mathbb{E}(T(X_1, \dots, X_n)) = c(X)$$

za vsako dopustno porazdelitev. Natančneje: za vsako dopustno porazdelitev (k.p.f.)  $F \in \mathcal{F}$  in vsak vzorec  $X_1, \dots, X_n \stackrel{NEP}{\sim} F$  velja

$$\mathbb{E}(T(X_1, \dots, X_n)) = c(F).$$

**Definicija 8.2.** Naj bosta  $U$  in  $V$  *nepristranski* cenilki za  $c(X)$  v modelu  $\mathcal{F}$ . Tedaj ima  $U$  enakomerno manjšo varianco od  $V$ , če velja

$$\text{Var}(U(X_1, \dots, X_n)) \leq \text{Var}(V(X_1, \dots, X_n))$$

$\forall F \in \mathcal{F}$  in vsak vzorec  $X_1, \dots, X_n \stackrel{NEP}{\sim} F$ .

**Definicija 8.3.** Zaporedje cenilk  $T_n$  za karakteristike  $c$ , je *dosledno* (angl. *consistent*), če  $\forall F \in \mathcal{F}$  in vsako neskončno zaporedje  $X_1, X_2, \dots \stackrel{NEP}{\sim} F$  zaporedje  $T_n(X_1, \dots, X_n)$  konvergira h konstanti  $c(F)$  verjetnostno.

**Komentar.** Če  $X_1, X_2, \dots$  generiramo kot *neodvisne* replikacije slučajne spremenljivke  $X : \Omega \rightarrow \mathbb{R}$ , lahko  $X_i$  razumemo kot funkcijo na prostoru neskončnih vzorcev

$$S = \Omega^{\mathbb{N}} = \{\text{neskončna zaporedja iz } \Omega\}.$$

---

<sup>2</sup>npr.  $c = \mathbb{E}(X)$ ,  $c = \text{Var}(X)$ ,  $c = \mathbb{P}(X \geq 2)$ , ...

## 8.1 Metode za konstrukcijo cenilk

**Metoda 1** (Metoda momentov). Zanima nas karakteristika  $c(X)$  proučevane slučajne spremenljivke  $X : \Omega \rightarrow \mathbb{R}$  v nekem modelu. Če je  $c(X)$  mogoče izraziti z momenti kot  $c(X) = g(m_1, m_2, \dots, m_r)$ , potem  $c(X)$  ocenjujemo s cenilko  $\hat{c} = g(\hat{m}_1, \hat{m}_2, \dots, \hat{m}_r)$ . Če je  $g$  zvezna, je cenilka  $\hat{c}$  dosledna. V praksi imamo najpogostejše parametrični model z vektorskim parametrom  $\vartheta = (\vartheta_1, \dots, \vartheta_r)$ , kjer izrazimo

$$\begin{aligned} m_1 &= m_1(\vartheta_1, \dots, \vartheta_r) \\ &\vdots \\ m_r &= m_r(\vartheta_1, \dots, \vartheta_r) \end{aligned}$$

Privzemimo, da znamo zgornji sistem razrešiti na  $\vartheta$  z vektorsko funkcijo  $(\vartheta_1, \dots, \vartheta_r) = (g_1(m_1, \dots, m_r), \dots, g_r(m_1, \dots, m_r))$ . Potem za  $\vartheta$  vzamemo cenilko

$$\hat{\vartheta} = (g_1(\hat{m}_1, \dots, \hat{m}_r), \dots, g_r(\hat{m}_1, \dots, \hat{m}_r)).$$

Že vemo: če je  $g = (g_1, \dots, g_r)$  zvezna, je  $\hat{\vartheta}$  dosledna.

**Metoda 2** (Metoda največjega verjetja). Privzemimo parametrični model s prostorom parametrov  $\Theta \subset \mathbb{R}^r$  in splošnim parametrom  $\vartheta = (\vartheta_1, \dots, \vartheta_r) \in \Theta$ . Dalje privzemimo, da imajo dopustne porazdelitve verjetnostne funkcije (v diskretnem modelu) oz. gostote (v zveznem modelu) oblike

$$f(x; \vartheta) = f(x; \vartheta_1, \dots, \vartheta_r).$$

**Definicija 8.4.** Funkcija verjetja za vzorec velikosti  $n$  je  $L : \mathbb{R}^n \times \Theta \rightarrow [0, \infty)$ ,

$$L(x_1, \dots, x_n; \vartheta) = f(x_1; \vartheta) \cdot \dots \cdot f(x_n; \vartheta).$$

Kot funkcija vzorca  $\vec{x} = (x_1, \dots, x_n)$  je  $L$  gostota vektorja  $(x_1, \dots, x_n)$ . V teoriji verjetja  $L$  pri danem  $\vec{x}$  gledamo kot funkcijo parametra  $\vartheta$ . Ocenimo za  $\vartheta$  pri danem  $\vec{x}$  po metodi najmanjših kvadratov je tak  $\hat{\vartheta} \in \Theta$ , pri katerem ima  $L(\vec{x}; \vartheta)$  maksimum, torej velja:

$$L(\vec{x}; \hat{\vartheta}) = \max_{\vartheta \in \Theta} L(\vec{x}; \vartheta).$$

Oceno  $\hat{\vartheta}$  analitično tipično izračunamo z odvajanjem. Zaradi preprostosti raje odvajamo logaritemsko funkcijo verjetja:

$$\ln(L(\vec{x}; \vartheta)) = \sum_{i=1}^n \ln f(x_i; \vartheta).$$

Stacionarne točke funkcije  $\ln L$  imenujemo rešitve *enačb verjetja* (EV)

$$\frac{\partial}{\partial \vartheta_j}(\ln L) = 0, \quad 1 \leq j \leq n.$$

**Definicija 8.5** (Cenilka največjega verjetja). Če za vse možne (v diskretnem primeru) ali skoraj vse (v zveznem primeru) realizacije  $\vec{x}$  slučajnega vektorja  $\vec{X}$  obstaja ocena  $\hat{\vartheta}(\vec{x})$  za  $\vartheta$  po metodi največjega verjetja, to je

$$\max_{\vartheta \in \Theta} L(\vec{x}; \vartheta) = L(\vec{x}; \hat{\vartheta}(\vec{x})),$$

potem funkciji  $\hat{\vartheta} : \mathbb{R}^n \rightarrow \bar{\Theta}$  pravimo *cenilka največjega verjetja* (CNV) za  $\vartheta$ .

**Opomba.** Imamo parametrični model s parametričnim prostorom  $\Theta$ .

- Množica “možnih” vrednosti se ne spreminja s  $\vartheta$ .
- Za “skoraj vse vrednosti” se ne spreminja s  $\vartheta$ : če je  $D_{\hat{\vartheta}}$  definicijsko območje, mora veljati

$$\mathbb{P}((X_1, \dots, X_n) \in D_{\hat{\vartheta}}) = 1$$

za vsako dopustno porazdelitev,  $\forall \vartheta$  in  $\forall X_i \stackrel{NEP}{\sim} \vartheta$ .

**Izrek 8.1.** Naj bodo gostote (verjetnostne funkcije)  $f(\vec{x}; \vartheta)$  *dvakrat zvezno parcialno odvedljive* na  $\vartheta_j$ , naj bo  $\{\vec{x} \mid f(\vec{x}; \vartheta) > 0\}$  *neodvisna* od  $\vartheta$  in naj veljajo še dodatni blagi regularnostni privzetki. Če imajo (EV) enolične rešitve za vse dovolj velike vzorce, ki jih označimo  $\hat{\vartheta} = \hat{\vartheta}(x_1, \dots, x_n)$ , potem je  $\hat{\vartheta}(x_1, \dots, x_n)$  dosledno zaporedje cenilk za  $\vartheta$ .

## 9 INTERVALSKO OCENJEVANJE

**Definicija 9.1.** Naj bo  $c = c(X) = c(F_X)$  proučevana karakteristika slučajne spremenljivke  $X$ . Naj bo  $\alpha \in (0, 1)$  vnaprej podano (“majhno”) in naj bo  $n$  velikost vzorca. Interval zaupanja za  $c$  stopnje zaupanja  $1 - \alpha$  je prireditev  $\vec{X} = (X_1, \dots, X_n) \mapsto [L(X_1, \dots, X_n), U(X_1, \dots, X_n)]$  za katero velja:

$$\mathbb{P}([L(X_1, \dots, X_n), U(X_1, \dots, X_n)] \ni c(F)) \geq 1 - \alpha$$

za vsako dopustno porazdelitev  $F$  in  $\forall X_1, \dots, X_n \stackrel{NEP}{\sim} F$ .

**Komentar.** Interval zaupanja je določen s funkcijama  $L, U : \mathbb{R}^n \rightarrow \mathbb{R}$ .

**Izrek 9.1** (Student, Fisher). Naj bodo  $X_1, \dots, X_n \stackrel{NEP}{\sim} \mathcal{N}(\mu, \sigma^2)$ . Tedaj sta

$$\bar{X} = \frac{1}{n}(X_1 + \dots + X_n) \quad \text{in} \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

neodvisni slučajni spremenljivki. Velja

$$\frac{n-1}{\sigma^2} \cdot S^2 = \sum_{i=1}^n \left( \frac{X_i - \bar{X}}{\sigma} \right)^2 \sim \chi_{n-1}^2 = \Gamma\left(\frac{n-1}{2}, \frac{1}{2}\right).$$

**Definicija 9.2.** Naj bosta  $Z$  in  $K$  neodvisni slučajni spremenljivki in  $Z \sim \mathcal{N}(0, 1)$  ter  $K \sim \chi_k^2$ . Tedaj pravimo, da ima slučajna spremenljivka  $\frac{Z}{\sqrt{\frac{K}{k}}}$  Studentovo porazdelitev s  $k$  prostorskimi stopnjami. Označimo jo s  $t_k$ .

**Komentar.** Porazdelitev  $t_k$  je zaradi neodvisnosti funkcija porazdelitve slučajne spremenljivke  $Z$  in slučajne spremenljivke  $K$ . Takoj sledi, da je  $t_k$  simetrična okrog 0. Očitno sta  $\frac{Z}{\sqrt{\frac{K}{k}}}$  in  $\frac{-Z}{\sqrt{\frac{K}{k}}}$  enako porazdeljeni.



**Posledica.** Slučajna spremenljivka

$$t = \frac{\overline{X} - \mu}{\frac{S}{\sqrt{n}}} \sim t_{n-1}$$

(tu je  $S = \sqrt{S^2}$ ).

## 10 PREIZKUŠANJE DOMNEV

**Definicija 10.1.** Statistična domneva (hipoteza) je izjava, da porazdelitev slučajne spremenljivke  $X$  pripada neki podmnožici  $\mathcal{H} \subseteq \mathcal{F}$ .

**Definicija 10.2.** Preizkus domneve  $\mathcal{H}$  proti alternativni  $\mathcal{A}$  za vzorec velikosti  $n$  je odločitveno pravilo, ki na podlagi realizacije  $n$  neodvisnih replikacij proučevane slučajne spremenljivke odloči, ali  $\mathcal{H}$  zavrnemo (in s tem sprejmemo  $\mathcal{A}$ ) ali je ne zavrnemo (oz. jo “sprejmemo”).

**Komentar.** Verjetnost napake 1. vrste je funkcija, definirana na domnevi  $\mathcal{H}$ . Če je  $\mathcal{H}$  sestavljena iz ene porazdelitve (“enostavna”), je to v resnici eno število.